

# 电动汽车锂电池健康状态估计和剩余使用寿命预测的端到端神经网络框架

- An end-to-end neural network framework for state-of-health estimation and remaining useful life prediction of electric vehicle lithium batteries
- 作者: Penghua Li a, Zijian Zhang , Radu Grosu, Zhongwei Deng c, Jie Hou, Yujun Rong, Rui Wu
- 期刊: Renewable and Sustainable Energy Reviews
- 发表时间: 2022

## 摘要

- 提出: 一个针对状态健康(SOH)估计和剩余使用寿命(RUL)预测的端到端预后框架
- 方法:
  - 1) 混合神经网络(NN), 一维卷积神经网络和活动状态跟踪长-短期记忆神经网络的串联, 被设计用来捕获影响电池退化的几个变量之间的层次特征, 以及这些特征中嵌入的时间依赖性。
  - 2) 通过Kolmogorov-Smirnov检验, 建立了应用于SOH或RUL任务的流行nn的超参数先验分布。将这种先验分布作为代理来研究退化数据对此类神经网络建模的影响。
  - 3) 提出了一种贝叶斯优化算法, 建立SOH和RUL模型, 在超参数的顺序演化过程中自动选择最优配置。
- 结果: 与现有的神经网络相比, 该方法在SOH和RUL任务上的有更低的平均RMSE为0.0072, 全局平均RMSE为0.0269

## 1.引言

- 针对无法直接在线测量容量或内阻以往提出的方法:
  - 1) 数学模型: 增量容量分析、差分电压分析等被广泛应用与估计SOH

- 2) 机理模型：偏微分方程模拟质量和电荷与老化密切相关的转移动力学，如以P2D模型闻名的电池化学模型、或通过分析物理和化学反应来描述电池动态响应和降解行为，如等效电路模型
- 3) 数据驱动：神经网络具有自适应性、灵活性并且没有任何物理化学机制

RUL和SOH共同预测-关于NN的使用，为了获得准确的结果，在文献中主要可以追溯到两种方法：

- 1) 建立个体预测模型，如标准LSTM NN (S-LSTM NN)的dropout技术和Adam算法，双向LSTM NN[24]和ASTLSTM NN
- 2) 将不同的模型进行组合，旨在取单体模型在电池时间序列处理中的强度，综合预测RUL。如Elman NN与LSTM NN[21]的组合，CNN与LSTM NN的杂交[25,26]。

#### 创新点：

- 提出一个端到端预测框架，该框架通过改进的贝叶斯优化算法，帮助研究人员减少了调优超参数的手工工作量，简化了使用各种nn构建SOH/RUL模型的过程。
  - 提出了一种新的AST-LSTM神经网络与一维CNN的组合方法，即CNN- astlstm神经网络，该方法可以分层捕获退化数据的特征，并主动学习这些特征中嵌入的时间依赖性。
  - 提出了一种改进的贝叶斯优化算法，实现了神经网络在SOH和RUL任务中的自动超参数配置，减少了人工对神经网络训练过程的干预，使结果更容易推广和再现

#### 2.方法

数据端a、自动建模b、结果端c

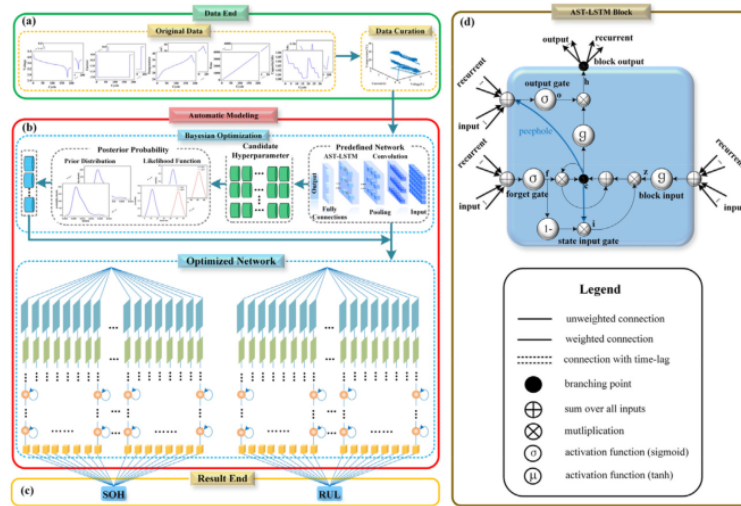


Fig. 1. The end-to-end prognostic framework, where (a)–(d) are the data-end, automatic modeling process, result-end, and AST-LSTM block, respectively.

## 过程：

- 在数据端，策划测量的电池样本适用于SOH和RUL任务。
- 在自动建模过程中，利用KS检验研究了神经网络超参数的先验分布。然后，我们结合这种先验分布和后续训练过程中产生的后验超参数分布，自动优化基于神经网络的模型。
- 结果端输出预期的SOH或RUL。

## CNN-ASTLSTM NN 设计

- 卷积层的获取方式

$$\mathbf{F}_{n,(x,c_{out})} = \sigma \left( \sum_{i,c_{in} \in \mathcal{N}_n^K} \mathbf{K}_{n,i,c_{in},c_{out}} \mathbf{U}_{n,s \times x + i,c_{in}} \right)$$

- 最大池化的获取方式

$$\mathbf{U}_{n+1,(x,c_{out})} = \mathbf{Y}_{n,(x,c_{out})} = \max_{0 \leq j \leq Q-1} \{ \mathbf{F}_{n,d \times x + j,c_{out}} \}$$

## CNN-ASTLSTM NN神经网络的超参数优化

- 损失的期望泛化误差

$$\theta^* = \operatorname{argmin}_{\theta \in \Theta} \mathbb{E}_{\mathbf{U} \sim \mathcal{G}_{\mathbf{U}}} [\mathcal{L}(\mathbf{U}; \mathcal{A}_{\theta}(\mathcal{D}_{\mathbf{U}}))]$$

- 交叉验证

$$\theta^* = \operatorname{argmin}_{\theta_c, \theta_a \in \Theta^{(i)}} \frac{1}{k} \sum_{i=1}^k \mathcal{L}(\mathcal{A}_{\theta_c}^{(i)}, \mathcal{A}_{\theta_a}^{(i)}, \mathcal{D}_{\mathbf{U}, \text{train}}^{(i)}, \mathcal{D}_{\mathbf{U}, \text{valid}}^{(i)})$$

- C为CNN超参数指定的学习算法 A是AST-LSTM NN 超参数

- 

$$EI_{e^*}(\theta_{c,a}) := \int_{-\infty}^{\infty} \max(e^* - e, 0) P_{\mathbb{F}}(e | \theta_{c,a}) de$$

- EI 是CNN-ASTLSTM NN下的期望值

- CNN-ASTLSTM NN的应用

- 应用 CNN-ASTLSTM NN 训练一个 SOH 估计模型的问题可以描述为:

- 

$$SOH := \frac{\mathbb{E}(\mathbf{U}_{(\mathbf{V}, \mathbf{T}, \mathbf{I}, \mathbf{t}), t}^{H_i}, \mathbf{U}_{(\mathbf{V}, \mathbf{T}, \mathbf{I}, \mathbf{t}), t+1}^{H_i}, \dots, \mathbf{U}_{(\mathbf{V}, \mathbf{T}, \mathbf{I}, \mathbf{t}), t+s_w-1}^{H_i} | U_C^{H_i})}{C_0} \times 100\%$$

- 实际和预测的 RUL 定义为

- 

$$RUL = q_{eol} - q_s$$

$$\widehat{RUL} = \hat{q}_{eol} - q_s$$

- 

$$\hat{q}_{eol}^{(train)} := \mathbb{E}(U_{C, q_s}^H, U_{C, q_s-1}^H, \dots, U_{C, q_s-s_w+1}^H | U_{C, q_s+1}^H, \dots, U_{C, q_s+p_w}^H)$$

- 

### 3.数值实验

- 在SOH任务中随机选取70%和30%作为训练数据和测试数据。
- 对于RUL任务，我们从3个单元(#5,6,18)中选择前50个周期的数据作为训练数据，其余的周期数据作为测试数据。

- 此外，为了评估各种模型的稳健性，我们选择了 16 个单元格（#29-34、36、38-44、49、52）数据来测试容量预测。所有这些数据都不参与这些模型的训练。



#### 4.结论

- 本研究提出了一个端到端的预测框架，用于自动提取电池退化数据的层次特征并优化 NN 的超参数。我们已经描述了我们利用 AST-LSTM NN 的想法和网络设计的进步来交付 CNN-ASTLSTM NN 的努力。我们还展示了如何应用 KS 测试来获得超参数的先验分布。这种先验分布被视为评估电池数据对 SOH 或 RUL 任务期间 NN 建模过程影响的替代指标。为了自动选择最有希望的超参数配置，我们还将这种先验分布引入贝叶斯优化算法来构建 SOH 和 RUL 模型。与现有的神经网络相比，实验表明我们的方法达到了较低的 ARMSE 0.0072 和 GARMSE 0.0269 分别用于 SOH 和 RUL 任务。我们还使用了在未来实际应用中将考虑的指标，例如 FLOPs、参数、训练时间和推理延迟，对现有的基于 NN 的方法进行全面分析。相关结果表明，我们的方法实现了最佳的权衡性能。

- 均方根误差

$$\text{RMSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2}$$

以上内容整理于 [幕布文档](#)