

DOI: 10.3901/JME.2022.10.180

# 基于信息熵与 PSO-LSTM 的锂电池组健康状态估计方法<sup>\*</sup>

张朝龙<sup>1,2</sup> 赵筛筛<sup>1</sup> 何怡刚<sup>2</sup>

(1. 安庆师范大学电子工程与智能制造学院 安庆 246011;  
2. 武汉大学电气与自动化学院 武汉 430072)

**摘要:** 针对目前锂电池组健康状态估计方法的不足, 提出一种基于信息熵与粒子群算法(Particle swarm optimization, PSO)优化长短时记忆神经网络(Long short-term memory neural network, LSTM)的锂电池组健康状态估计方法。基于锂电池组恒流-恒压充电阶段锂电池组内各单体端电压的信息熵和平均温度信息, 应用 PSO-LSTM 方法提取锂电池组电压熵、平均温度和锂电池组健康状态之间的映射关系, 从而建立锂电池组健康状态估计模型。应用试验室测量的锂电池组老化数据对提出的方法进行测试。测试结果表明, 该方法能够准确估计锂电池组的健康状态, 平均估计误差在 1% 以内。同时, 为验证提出的方法可推广至锂电池单体, 利用美国航天航空局测得的锂电池加速老化数据再次测试, 平均估计误差在 0.7% 以内。并针对锂电池组与锂电池单体设计对比试验, 进一步验证提出的方法具有良好的估计性能。

**关键词:** 锂电池组; 健康状态; 信息熵; 粒子群算法; 长短时记忆神经网络

**中图分类号:** TM910

## State-of-health Estimate for Lithium-ion Battery Using Information Entropy and PSO-LSTM

ZHANG Chaolong<sup>1,2</sup> ZHAO Shaishai<sup>1</sup> HE Yigang<sup>2</sup>

(1. School of Electronic Engineering and Intelligent Manufacturing, Anqing Normal University, Anqing 246011;  
2. School of Electrical and Automation, Wuhan University, Wuhan 430072)

**Abstract:** In order to address the shortcoming of the existing lithium-ion battery pack state of health(SOH) estimation methods, a SOH estimation approach for lithium-ion battery pack using information entropy and particle swarm optimization(PSO) to optimize the long short-term memory(LSTM) neural network is proposed. The data of the information entropy and the average temperature of each cell terminal voltage in the lithium-ion battery pack during the constant current-constant voltage charging stage are utilized to extract the mapping relationship between the voltage entropy, average temperature, and SOH of the lithium-ion battery pack using PSO-LSTM, and then establish the lithium-ion battery pack SOH estimation model. The measured aging data of lithium-ion battery pack in the laboratory are employed to verify the validity of the presented method. The results show that the developed approach can accurately estimate the SOH of the lithium-ion battery pack with the average estimation error within 1%. Meanwhile, in order to verify the proposed method can be extended to lithium-ion batteries, the accelerated aging data of lithium-ion batteries measured by National Aeronautics and Space Administration(NASA) to test again with the average estimation error within 0.7%. The compared experiment is designed for the battery pack and cells, which further demonstrates that the suggested method offers a favorable estimation performance.

**Key words:** lithium-ion battery pack; state of health; information entropy; particle swarm optimization; long short-term memory neural network

<sup>\*</sup> 国家自然科学基金(51637004, 51607004)、国家重点研发计划(2016YFF0102200)、安徽高校协同创新(GXXT-2019-002)、安徽高校自然科学基金研究重点(KJ2020A0509)和安庆师范大学研究生学术创新(2021yjsXSCX009)资助项目。20210802 收到初稿, 20220320 收到修改稿

## 0 前言

锂离子电池因其重量轻、功率密度高、循环寿命长和自放电率低等优异特点,成百上千节锂离子电池单体通常以串并联的形式构成锂离子电池模组,在电动汽车、电网等电气化领域中被广泛应用<sup>[1-5]</sup>。然而,锂离子电池的退化现象始终伴随着锂离子电池的使用<sup>[6-7]</sup>。当锂离子电池最大放电容量退化至额定容量的 70%~80%时,将不再适合新能源汽车的使用。因此,准确监测锂电池健康状态,对提前预知锂离子电池失效与退役,提高锂电池安全性非常重要。健康状态作为评价锂电池状态的重要指标之一,通常用于量化电池的老化程度和健康状态。但锂离子电池复杂和非线性的电化学机理一直是准确估计其健康状态的技术难点<sup>[8-9]</sup>,也是利用各种先进理论去解决该难点的主要动力。为准确估计锂电池的健康状态,诸多方法被提出,可主要分为直接测量法、模型驱动的方法和数据驱动方法三大类。

直接测量锂电池健康状态的方法通常包括库仑计数法、开路电压法以及电化学阻抗谱法。库仑计数法通过对锂电池进行充分的充放电后获取锂电池静态健康状态<sup>[10-11]</sup>;开路电压法则需要进行大量的试验获得锂电池健康状态与开路电压之间的关系<sup>[12-13]</sup>;阻抗谱法使用宽频谱测定锂电池的健康状态<sup>[14]</sup>。该方案简单直观,但耗时较长,仅适用于专业的试验室环境,直接限制直接测量方法的实际应用与推广。

模型驱动的方法可以进一步分为基于退化模型的方法与状态观测器两类。为表征电池的老化机理,有研究工作提出电化学模型与相对简单的半经验模型<sup>[15-16]</sup>。电化学模型为电池的老化机理提供一定程度上的解释,但基于电化学的老化模型计算量大且并未直接解决健康状态的估计问题。相对简单的半经验模型没有对导致电池退化的电化学过程深入研究,但它们揭示应力因素对电池健康状态的影响。半经验模型的性能在很大程度上取决于测试数据的质量和数量。基于状态观测器的方法常常采用等效电路模型与扩展卡尔曼滤波<sup>[17]</sup>或粒子滤波<sup>[18]</sup>等滤波算法结合后,将健康状态估计问题转化为参数估计问题。然而,滤波算法的有效性和适用性对锂电池模型的精确度非常敏感,易受到系统的复杂程度和实际应用环境的不确定性影响。

数据驱动的方法由于能够描述复杂的退化过程而不需要深入的机理研究受到越来越多学者的关

注。该方法通过利用锂电池的历史数据将外部特性映射到锂电池的放电容量,从而自动的对锂电池健康状态进行估计。这类方法进一步可主要分为四类①从老化周期直接映射到锂电池健康状态;②从原始数据中获取的变量映射到锂电池健康状态;③信号处理方法;④统计指标法<sup>[19]</sup>。从老化周期直接映射到锂电池健康状态的方法具有良好的非线性映射性<sup>[20]</sup>。人工神经网络<sup>[21]</sup>、模糊逻辑<sup>[22]</sup>和支持向量机<sup>[23]</sup>等方法基于输入的数据自动建立黑箱模型,将可获取的变量映射到锂电池健康状态。信号处理的方法通常包括容量增量分析法<sup>[24]</sup>、差分电压分析法<sup>[25]</sup>和差热伏安法<sup>[26]</sup>。这类方法通常需要回归技术进一步处理应用。统计指标法包括相关性分析、样本熵等。这些方法的缺点是对锂电池数据的数量和质量比较敏感。长短时记忆神经网络(Long short-term memory neural network, LSTM)作为一种循环神经网络,能够维持梯度不消失<sup>[27]</sup>且长时间有效地存储和更新信息,因此常被用来估计锂电池健康状态,但是对于如何设置 LSTM 最佳的学习率并没有合适的方法。粒子群算法(Particle swarm optimization, PSO)是一种高效的参数寻优算法,通过不断更新粒子的速度和位置,跟踪局部最优解,找到全局最优解,并以精度高、收敛快、速度快等优点被广泛应用于众多领域<sup>[28]</sup>。

为提高锂电池组健康状态的估计精度,往往利用大量的数据构建锂电池组健康状态估计模型。然而,在实际应用中,测量的数据往往受到干扰、测量误差、随机负载等未知因素的影响。为应对这一问题,提出一种基于信息熵与 PSO-LSTM 的锂电池组健康状态估计方法。利用恒流-恒压充电阶段的锂电池组内各单体电压熵和平均温度有效地反映电池容量退化,进一步利用 PSO 算法改进的 LSTM 神经网络获取锂电池组电压熵、平均温度和健康状态之间的映射关系,建立锂电池组健康状态估计模型,从而对锂电池组健康状态精准估计。应用试验室测量的锂电池组老化数据对提出的方法进行测试。测试结果表明,该方法能够准确估计锂电池组的健康状态,平均估计误差在 1% 以内。同时,为验证提出的方法可推广至锂电池单体,利用美国航天航空局(National Aeronautics and Space Administration, NASA)测得的锂电池加速老化数据再次验证验证的结果,平均估计误差在 0.7% 以内。并针对锂电池组与锂电池单体设计对比试验,将所提方案与其它常用方法进行比较,进一步验证提出的方法具有良好的估计性能。

## 1 锂电池组健康状态

锂电池组健康状态可以从容量和内阻两个角度进行定义, 定义式可表示为

$$\text{SOH} = \frac{C_{\text{presented capacity}}}{C_{\text{initial capacity}}} \times 100\% \quad (1)$$

$$\text{SOH} = \frac{R_{\text{terminated resistance}} - R_{\text{presented resistance}}}{R_{\text{terminated resistance}} - R_{\text{initial resistance}}} \times 100\% \quad (2)$$

式中,  $C_{\text{presented capacity}}$  为当前锂电池组最大放电容量,  $C_{\text{initial capacity}}$  为锂电池组额定容量。 $R_{\text{terminated resistance}}$ ,  $R_{\text{presented resistance}}$ , 和  $R_{\text{initial resistance}}$  分别代表电池寿命终止时, 目前状态, 以及初始状态的欧姆内阻。

由于容量定义法更为精确且参量容易获取。因此, 以容量的角度对锂离子电池组健康状态进行定义。

## 2 信息熵

信息熵是由克劳德·艾尔伍德·香农于 1948 年提出的一种定量测量系统无序性或混乱程度的统计量。因此也被称为香农熵。信息熵自提出以来, 已被广泛应用于许多科学领域, 如电池健康监测<sup>[29]</sup>、电动汽车<sup>[30]</sup>等。由于信息熵主要依赖于概率分布, 因此可以更好地表征数据的不确定性, 并有效地反映数据所携带的信息量。信息熵越低, 数据的有序度越高。反之, 信息熵越高, 说明数据所携带的信息是分散的。信息熵定义<sup>[31]</sup>为

$$S = - \sum_{i=1}^n p_i \lg p_i \quad (3)$$

式中,  $p_i$  为第  $i$  个样本采样点的概率,  $n$  为表示所有采样点总数的总数。

准确估计锂电池组健康状态通常需要大量的数据建立锂电池组健康状态估计模型, 但实际测量的数据往往包含各种噪声。基于含有噪声的数据估计锂电池组健康状态会产生较大的误差且直接提高估计难度。因此, 需要对原始数据进一步处理, 提取有效特征。经过多次尝试发现, 利用信息熵量化电池数据的规律性和不确定性, 提取原始数据中的有效特征, 每个充电阶段将成百上千个采样电压化为一个电压熵值, 即可以有效降低对实际应用的计算复杂度, 又能够很好地映射锂电池组退化过程。

## 3 PSO-LSTM

### 3.1 LSTM 神经网络

由于锂电池组的健康状态随着不断地充放电而退化, 故可以将锂电池组健康状态的退化过程视为时间序列过程, 它可以覆盖数千次充放电循环, 代表锂电池组的退化演化。故锂电池组历史运行数据与其健康状态存在长期依赖关系, 因此采用时间序列分析方法 LSTM 神经网络, 采集锂电池组不同充电次数的充电阶段的电压熵与温度数据, 估计其对应放电阶段的健康状态。LSTM 神经网络是一种循环神经网络, 常见的循环神经网络结构如图 1 所示。其中,  $x$  为输入,  $h$  为输出,  $t$  为时间,  $w$ 、 $u$ 、 $v$  为网络参数。




图 1 循环神经网络结构

可以看出, 隐含层的输出中带有当前的信息状态, 作为下一层的输入被传递到下一个隐含层。这一显著特征保留前一步的信息, 从而提高循环神经网络对时间序列问题的学习能力。然而, 对于长期依赖问题, 循环神经网络存在梯度消失现象, 导致数据信息不能远距离转移。

对于循环神经网络的梯度消失问题, 目前最有效的解决方案是 LSTM 神经网络。LSTM 神经网络的设计关键是将非线性和数据相关的控制单元纳入循环神经网络单元, 循环神经网络单元可以经过训练, 以确保与状态信号相关的目标函数的梯度不会消失。LSTM 神经网络基本结构如图 2 所示。显然, LSTM 神经网络隐含层的内部结构比循环神经网络更为复杂。LSTM 神经网络主要包括存储单元、遗忘门、输入门和输出门。遗忘门可以丢弃多余的信息, 输入门能够选择要存储在内部状态的关键信息, 输出门用于确定输出信息。利用记忆单元的状态, 借助三门选择性地添加或删除信息。因此, LSTM 神经网络可以在长时间内有效地存储和更新关键信息, 而不会出现梯度消失的情况。

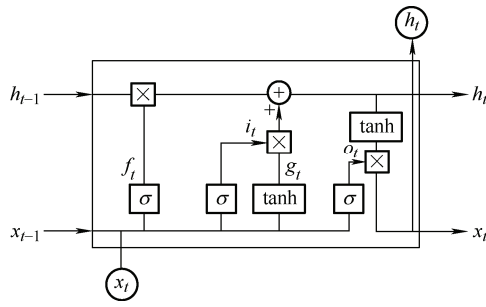


图 2 LSTM 神经网络基本结构

LSTM 神经网络对数据的处理过程如下所述<sup>[31]</sup>。

(1) 根据式(4)，在遗忘门  $f_t$  中舍弃上一个单元  $c_{t-1}$  中不需要的信息

$$f_t = \sigma(w_f x_t + u_f h_{t-1} + b_f) \quad (4)$$

(2) 分别由式(5)、(6)更新输入量  $i_t$  以及  $\tilde{c}_t$  单元

$$i_t = \sigma(w_i x_t + u_i h_{t-1} + b_i) \quad (5)$$

$$\tilde{c}_t = \tanh(w_c x_t + u_c h_{t-1} + b_c) \quad (6)$$

(3) 更新  $c_t$  单元

$$c_t = f_t \cdot c_{t-1} + i_t \cdot \tilde{c}_t \quad (7)$$

(4) 根据输入量  $o_t$  与  $c_t$  生成输出  $h_t$

$$o_t = \sigma(w_o x_t + u_o h_{t-1} + b_o) \quad (8)$$

$$h_t = o_t \cdot \tanh(c_t) \quad (9)$$

式中， $w$  为输入权重， $u$  为循环权重； $f$ ， $i$  和  $o$  分别为遗忘门，输入门与输出门。 $b$  为偏置； $\sigma$  为激活函数， $\tanh$  为双曲正切函数且分别定义为

$$\sigma(x) = \frac{1}{1 + \exp(-x)} \quad (10)$$

$$\tanh(x) = \frac{\exp(x) - \exp(-x)}{\exp(x) + \exp(-x)} \quad (11)$$

学习率作为 LSTM 神经网络的重要超参数，控制着模型的学习进度，决定目标函数是否以及何时收敛到最优解。适当的学习率可以使目标函数在适当的时间内收敛到最优解。但学习率较大容易导致算法输出振荡，学习率较小则会造成过拟合和收敛缓慢。因此，对于 LSTM 神经网络，合适的学习率非常重要。故采用 PSO 算法优化 LSTM 神经网络的学习率。

### 3.2 PSO 算法

粒子群优化算法是一种基于群体搜索的全局优化算法。它是受鸟类群集或鱼类群集的启发而开发，用于解决许多科学和工程领域优化问题<sup>[32]</sup>。PSO 算法通过定义的适应度函数，不断更新粒子的速度和

位置从而达到全局最优解。粒子群算法在  $D$ -维空间中寻优的基本流程为

(1) 初始化粒子群算法，如种群规模  $N$ ，终止条件等。并随机生成每一个粒子  $i$  的速度  $v_i$  与位置  $x_i$

$$v_i = (v_{i1}, v_{i2}, \dots, v_{iD}) \quad i = 1, 2, \dots, N \quad (12)$$

$$x_i = (x_{i1}, x_{i2}, \dots, x_{iD}) \quad i = 1, 2, \dots, N \quad (13)$$

(2) 根据适应度函数，计算每一个粒子  $i$  的适应度值  $F[i]$ 。

(3) 根据式(14)、(15)生成全局最优解以及每一个粒子的局部最优解

$$p(i) = \begin{cases} F[i] & F[i] > p(i) \\ p(i) & \text{其他} \end{cases} \quad i = 1, 2, \dots, N \quad (14)$$

$$g = \begin{cases} F[i] & F[i] > g \\ g & \text{其他} \end{cases} \quad i = 1, 2, \dots, N \quad (15)$$

式中， $p_{best}(i)$  为粒子  $i$  的最优解， $g$  为全局最优解。

(4) 根据式(16)、(17)更新粒子的速度与位置

$$v_{id}^{k+1} = wv_{id}^k + c_1 r_{id}^k (p_{id}^k - x_{id}^k) + c_2 s_{id}^k (g^k - x_{id}^k) \quad (16)$$

$$x_{id}^{k+1} = x_{id}^k + v_{id}^{k+1} \quad (17)$$

式中， $r$  和  $s$  为随机常数， $k = 1, 2, \dots, H$  为迭代次数， $c_1$  与  $c_2$  为常数， $w$  为惯性常数<sup>[33]</sup>。

(5) 不断重复步骤(2)~(4)，直至达到算法终止条件，结束算法。

### 3.3 PSO 算法优化 LSTM 神经网络

采用平均绝对误差作为适应度函数，即锂电池组健康状态估计值与真实值间的误差作为适应度函数。PSO 优化 LSTM 神经网络学习率的步骤如图 3 所示，具体描述为

(1) 初始化 PSO 算法参数，如群体规模、粒子指标、迭代次数、粒子速度和位置、结束条件等。同时，根据经验设置 LSTM 神经网络的学习率范围。

(2) 根据适应度函数计算每个粒子的适应度值。

(3) 将每个粒子的当前适应度值与其历史适应度值进行比较，生成每个粒子的局部最优解。将粒子当前的适应度值与所有历史适应度值进行比较，得到全局最优解。

(4) 分别用式(16)和式(17)更新每个粒子的速度和位置。

(5) 重复步骤(2)~(4)，直至达到算法终止条件。

(6) 输出 PSO 算法优化后的 LSTM 神经网络学习率。



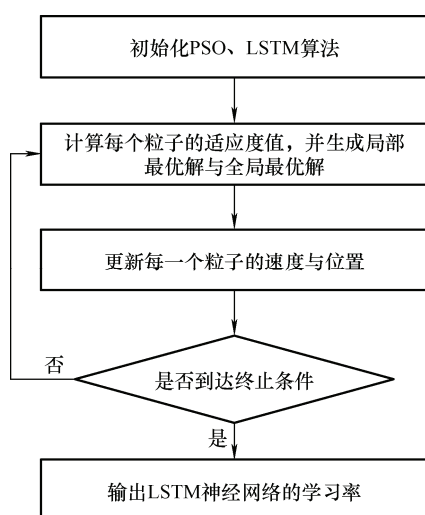


图 3 PSO 算法优化 LSTM 神经网络流程图

## 4 试验流程、结果与分析

### 4.1 试验数据

试验数据采用试验室测取的锂电池组老化数据和 NASA 数据库测得的锂离子电池加速老化数据。该锂电池组由 6 节同规格的锂离子单体电池串联而成，每节单体电池的标称容量和电压分别为  $2.4 \text{ A} \cdot \text{h}$  和  $3.6 \text{ V}$ 。阳极和阴极分别由石墨和  $\text{LiFePO}_4$  组成。表 1 为使用成组的锂电池单体详细特征参数。

表 1 18650 锂电池单体特征参数

参数	数值
阴极	$\text{LiFePO}_4$
阳极	石墨
额定容量/( $\text{A} \cdot \text{h}$ )	2.4
标称电压/V	3.6
允许电压范围/V	$3 \sim 4.2$
充电截止电流/mA	48
最大充电/放电电流/mA	2 400/7 200

基于实验室搭建的高性能电池测试系统，对锂离子电池组在室温下进行老化试验，测得锂电池组老化数据。高性能电池测试系统包括上位机、单体电池检测设备、电池组检测设备以及恒温箱。上位机用于记录和保存电池试验数据。单体电池及电池组检测设备具有高响应性、高精度、高效率等特点，可进行恒流、恒压、恒流恒压等测试模式，并可进行循环寿命测试、脉冲测试和脉冲功率测试等试验。试验装置如图 4 所示。




图 4 试验装置

锂电池组与 NASA 锂电池单体试验流程如图 5 所示。锂电池组老化试验以  $1.2 \text{ A}$  恒流充电，直至电池组端电压达到截止电压  $24.9 \text{ V}$ 。然后对电池组进行  $24.9 \text{ V}$  恒压充电，当电流降至  $48 \text{ mA}$  时停止充电。放电以  $2 \text{ A}$  恒流运行，直到电池组端电压降至  $19.3 \text{ V}$ 。当电池组的最大放电容量达到其失效阈值(约为额定容量的  $70\%$ )时，试验终止。NASA 锂电池单体电池 5 与电池 6 在  $24 \text{ }^\circ\text{C}$  进行加速老化试验。先以  $1.5 \text{ A}$  恒流充电直至电池端电压  $4.2 \text{ V}$ ，再维持  $4.2 \text{ V}$  恒压充电直至充电电流降至  $20 \text{ mA}$ 。锂电池 5 和 6 以  $2 \text{ A}$  恒流放电，直至电池端电压分别降至  $2.7 \text{ V}$  与  $2.5 \text{ V}$  停止。测量的锂电池组健康状态数据与锂电池 5、6 的健康状态数据如图 6 所示。

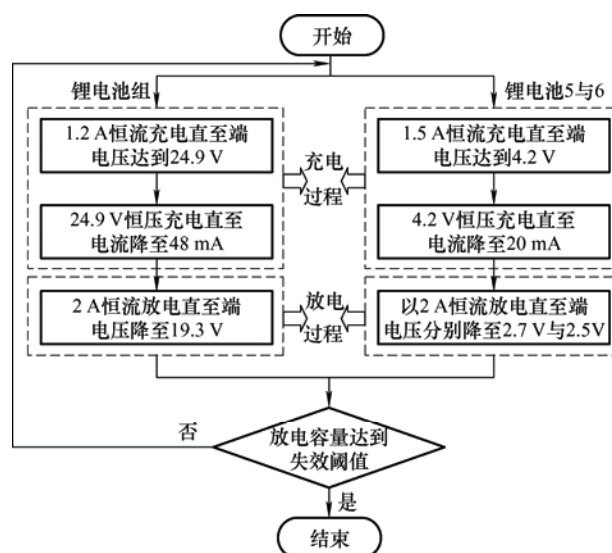


图 5 试验流程

由图 6 可以观察到，由于锂电池单体不一致、化学反应不可逆等原因，锂电池组健康状态一般会随着锂电池组的老化而下降。同理，随着试验的进

行, 锂电池 5、6 的健康状态因为老化而显著下降。






图6 锂电池组与锂电池单体健康状态数据

## 4.2 试验流程

本试验包括锂电池组健康状态估计和锂电池单体健康状态估计两部分。锂电池组健康状态估计试验具体步骤如图7所示, 具体描述如下。

(1) 根据恒流-恒压充电阶段锂电池组内各单体电池端电压与温度变化数据, 计算每次恒流恒压充

电阶段锂电池端电压数据的信息熵、平均温度与每个放电阶段后的健康状态数据, 生成处理后的数据集。

(2) 将处理后的数据集均分为训练集和测试集。

(3) 基于训练数据, 使用 PSO 算法对 LSTM 神经网络预处理, 对 LSTM 神经网络的学习率进行优化选择。

(4) 应用 PSO 算法优化获得的学习率, 基于优化后的长短时记忆神经网络建立锂电池组健康状态估计模型。

(5) 应用建立锂电池组健康状态估计模型, 基于测试数据估计锂电池组的健康状态。

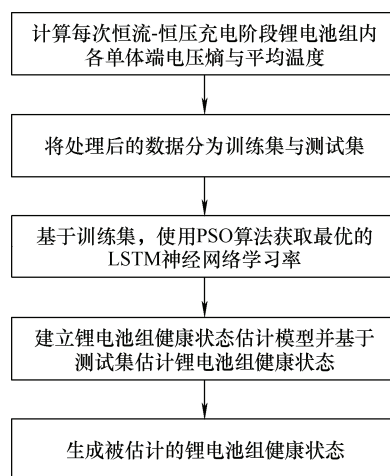



图7 试验步骤

## 4.3 试验结果与分析

基于训练集, 取锂电池组健康状态真实值与估计值的平均绝对误差为 PSO 算法适应度函数, 当锂电池健康状态真实值与估计值的误差连续 10 次以上(包括 10 次)小于 1% 时, PSO 算法停止。对锂电池组、电池 5 与电池 6 老化数据分别使用 PSO 算法优化 LSTM 神经网络学习率, 优化过程如图8所示。






图 8 PSO 算法优化 LSTM 神经网络过程

优化后的锂电池组与锂电池老化数据分别对应的 LSTM 神经网络学习率如表 2 所示。PSO 算法基于训练集优化 LSTM 学习率后,应用 LSTM 建立锂电池组健康状态估计模型。

表 2 优化后的 LSTM 神经网络学习率

数据类型	学习率
电池组	0.002 0
电池 5	0.000 3
电池 6	0.000 6

基于测试集,以不同老化时刻即经历不同充放电次数的锂电池组健康状态所对应的电压熵与平均温度信息为输入,应用建立的锂电池组健康状态估计模型估计对应充放电循环次数的锂电池组健康状态。试验结果如图 9 所示。锂电池组在不同老化时刻集不同充放电次数的估计结果如表 3 所示。可以看出,以平均温度和电压熵为输入并基于 PSO-LSTM 建立的锂电池组健康状态估计模型,在锂电池组不同老化状态及不同充放电次数下得到的健康状态估计结果与真实值之间误差在 1.5 % 以内,具有良好的稳定性。不同老化状态且提出的锂电池组健康状态估计方法对锂电池单体同样有效。

表 3 锂电池组在不同充放电次数下的估计误差

循环次数	估计误差(%)
230	0.26
250	0.58
270	0.51
290	1.02
310	0.93
330	0.84
350	1.40
370	0.6
390	0.16
410	1.47
430	0.75
449	1.15






图 9 试验结果

为进一步验证所提出的锂电池组健康状态估计方法的稳定性和通用性，对锂电池组、电池 5 和电池 6 从输入变量与算法两个角度设计比较试验。利用其他常用的电池状态估计算法开展测试，具体如表 4 所示。同时，基于测试集，随着电池老化的过程取电池老化进程中不同时刻的健康状态进行估计，估计的结果如图 10 所示。

表 4 比较试验

方法	输入	估计算法
提出的方法	电压熵、平均温度	PSO-LSTM
比较方法 1	电压、平均温度	PSO-LSTM
比较方法 2	电压熵、平均温度	BP NN
比较方法 3	电压熵	PSO-LSTM
比较方法 4	电压熵、平均温度	ELM








图 10 比较试验结果

图 11 分别展示电池组、电池 5 与电池 6 的估计误差。表 5 中记录的平均误差(Average error, AE)与最大误差(Maximal error, ME)。可以看出，对于不同的锂电池老化数据类型，五种方法都有较好的表现，但提出的方法的性能明显优于其他方法。








图 11 比较试验的估计误差

表 5 比较试验的估计结果

电池类型	指标	电池组	电池 5	电池 6
提出的方法	AE (%)	0.81	0.56	0.66
	ME (%)	1.47	1.07	1.24
比较方法 1	AE (%)	1.04	0.96	1.01
	ME (%)	1.82	1.76	1.51
比较方法 2	AE (%)	3.35	3.45	3.23
	ME (%)	4.47	4.29	3.56
比较方法 3	AE (%)	1.03	0.86	0.91
	ME (%)	1.72	1.26	1.35
比较方法 4	AE (%)	1.83	1.50	1.73
	ME (%)	2.73	2.18	2.53

对比试验 1 中, PSO-LSTM 算法的输入变量为每个充电阶段的电压和平均温度, 且对比试验 1 的 AE 和 ME 分别为 1.04% 和 1.82%。而所提方法以每个充电阶段的电压熵和平均温度训练 PSO-LSTM 算法从而获取健康状态估计模型, 使得所提方法的 AE 和 ME 分别为 0.81% 和 1.47%。直接显示信息熵的优越性, 量化电池老化数据的混乱程度和复杂性, 并减小训练集的大小, 能够较好地映射锂电池组健康状态退化。

同样, 提出方法的 AE 和 ME 明显低于对比方法 3。比较方法 3 不考虑温度数据作为输入, 但试验证明了温度在锂离子电池健康状态估算中起着不可或缺的作用。高温会提高电池的效率和性能, 同时加速一些不可逆的化学反应, 导致锂电池加速老化。低温下, 锂离子电池的放电容量和循环寿命会严重下降。

此外, 与使用反向传播(Back propagation, BP)神经网络的比较方法 2 相比, 比较方法 2 的 AE 与 ME 分别为 3.35% 和 4.47%。由于 LSTM 神经网络将非线性、数据相关的控制单元加入到结构框架中,

以确保在处理时间序列问题时, 与状态信号相关的目标函数的梯度不会消失。同时, 利用粒子群算法优化 LSTM 神经网络的学习率, 进一步提高了预测精度, 因此提出的方法在估计结果上明显优于比较方法 2。

与传统的神经网络相比, 极限学习机(Extreme learning machine, ELM)输入层和隐含层的连接权值、隐含层的阈值可以随机设定, 且设定完后不用再调整, 而 BP 神经网络则需要不断反向去调整权值和阈值。另外, 隐含层和输出层之间的连接权值不需要迭代调整, 而是通过解方程组方式一次性确定, 通过这样的规则, 提高算法精度与泛化能力。利用 ELM 进一步进行比较试验, AE 与 ME 分别为 1.83% 和 2.73%。结果发现, ELM 能够较好并稳定地估计健康状态, 但仍弱于 LSTM 对时间序列问题优秀的处理性能。

综合结果显示, 提出的方法具有更好的估计性能。与对比方法 1 和 3 相比, 提出的方法产生的 AE 和 ME 都较小, 说明电压熵与平均温度能够更有效地表征锂电池组容量退化的关键特征。同时, 对比方法 2 的 AE 和 ME 值均高于所提出的方法, 表明 PSO-LSTM 的估计精度高于 BP 神经网络。除此之外, 提出的方法利用信息熵值代替每次充电阶段成百上千个采样点, 相比于其他常用方法<sup>[34-35]</sup>, 降低了计算复杂度。另外, 提出的方法不仅适用于锂电池组的健康状态估计, 并可推广至锂电池单体的健康状态估计。

## 5 结论

(1) 提出一种基于信息熵与 PSO-LSTM 算法的锂离子电池组健康状态估计方法。从充电阶段的锂电池组内各单体端电压中提取的信息熵和平均温度作为表征电池容量损失的健康因子, 利用 PSO 算法优化 LSTM 神经网络的学习率, 从而更好地获取锂电池组内单体端电压信息熵、平均温度和健康状态之间的映射关系, 并进一步建立锂电池组健康状态估计模型。利用实验室测得的锂电池组老化数据验证该方法对锂电池组健康状态估计的有效性。试验结果表明, 提出的方法能够准确估计锂电池组的健康状态, 平均估计误差在 1% 以内。

(2) 将每次充电阶段成百上千个电压采样点利用一个熵值代替, 相比于其他常用方法, 降低计算复杂度。此外, 提出的方法可推广至锂电池单体的健康状态估计。基于 NASA 数据库中锂电池加速老

化数据进行锂电池单体健康状态估计试验, 结果表明, 提出的方法对于锂电池单体健康状态平均估计误差在 0.7 % 以内。并设计对比试验进一步将所提方法与其他方案进行比较, 证明所提方法具有较好的估计性能。研究结果对锂电池组与单体电池健康状态估计均具有极强的指导意义和参考价值。

## 参 考 文 献

- [1] YU Q, XIONG R, YANG R, et al. Online capacity estimation for lithium-ion batteries through joint estimation method[J]. *Applied Energy*, 2019, 255: 113817.
- [2] JIN Y, LIU K, LANG J, et al. An intermediate temperature garnet-type solid electrolyte-based molten lithium battery for grid energy storage[J]. *Nature Energy*, 2018, 3(9): 732-738.
- [3] 陈泽宇, 熊瑞, 李世杰, 等. 电动载运工具锂离子电池低温极速加热方法研究[J]. *机械工程学报*, 2021, 57(4): 113-120.
- CHEN Zeyu, XIONG Rui, LI Shijie, et al. Extremely fast heating method of the lithium-ion battery at cold climate for electric vehicle[J]. *Journal of Mechanical Engineering*, 2021, 57(4): 113-120.
- [4] 郑志坤, 赵光金, 金阳, 等. 基于库仑效率的退役锂离子动力电池储能梯次利用筛选[J]. *电工技术学报*, 2019, 34(增刊 1): 388-395.
- ZHENG Zhikun, ZHAO Guangjin, JIN Yang, et al. The reutilization screening of retired electric vehicle lithium-ion battery based on coulombic efficiency[J]. *Transactions of China Electrotechnical Society*, 2019, 34(Suppl.1): 388-395.
- [5] 黄鑫, 冯旭宁, 韩雪冰, 等. 车用并联电池组不均衡电流建模与仿真分析[J]. *机械工程学报*, 2019, 55(20): 44-51.
- HUANG Xin, FENG Xuning, HAN Xuebing, et al. Study on modelling and analysis of imbalanced current inside parallel-connected lithium-ion batteries for electric vehicle[J]. *Journal of Mechanical Engineering*, 2019, 55(20): 44-51.
- [6] 刘伟龙, 王丽芳, 王立业. 基于电动汽车工况识别预测的锂离子电池 SOE 估计[J]. *电工技术学报*, 2018, 33(1): 17-25.
- LIU Weilong, WANG Lifang, WANG Liye. Estimation of state-of-energy for electric vehicles based on the identification and prediction of driving condition[J]. *Transactions of China Electrotechnical Society*, 2018, 33(1): 17-25.
- [7] 华旻, 周思达, 何榕, 等. 车用锂离子动力电池组均衡管理系统研究进展[J]. *机械工程学报*, 2019, 55(20): 73-84.
- HUA Yang, ZHOU Sida, HE Rong, et al. Review on lithium-ion battery equilibrium technology applied for Evs[J]. *Journal of Mechanical Engineering*, 2019, 55(20): 73-84.
- [8] YANG Z, PATIL D, FAHIMI B. Online estimation of capacity fade and power fade of lithium-ion batteries based on input-output response technique[J]. *IEEE Transactions on Transportation Electrification*, 2018, 4(1): 147-156.
- [9] ZOU C, MANZIE C, NESIC D. A framework for simplification of PDE-based lithium-ion battery models[J]. *IEEE Transactions on Control Systems Technology*, 2015, 24(5): 1594-1609.
- [10] UNGUREAN L, CARSTOIU G, MICEA M V, et al. Battery state of health estimation: A structured review of models, methods and commercial devices[J]. *International Journal of Energy Research*, 2016, 41(2): 151-181.
- [11] NG K S, MOO C S, CHEN Yiping, et al. Enhanced coulomb counting method for estimating state-of-charge and state-of-health of lithium-ion batteries[J]. *Applied Energy*, 2009, 86(9): 1506-1511.
- [12] GUO Z, QIU X, HOU G, et al. State of health estimation for lithium-ion batteries based on charging curves[J]. *Journal of Power Sources*, 2014, 249: 457-462.
- [13] WENG C, SUN J, PENG H. A unified open-circuit-voltage model of lithium-ion batteries for state-of-charge estimation and state-of-health monitoring[J]. *Journal of Power Sources*, 2014, 258: 228-237.
- [14] LI D Z, WANG W, ISMAIL F. A mutated particle filter technique for system state estimation and battery life prediction[J]. *IEEE Transactions on Instrumentation and Measurement*, 2014, 63(8): 2034-2043.
- [15] CHRISTENSEN J, NEWMAN J. Effect of anode film resistance on the charge/discharge capacity of a lithium-ion battery[J]. *Journal of The Electrochemical Society*, 2003, 150(11): A1416-A1420.
- [16] CHRISTENSEN J, NEWMAN J. A mathematical model for the lithium-ion negative electrode solid electrolyte interphase[J]. *Journal of The Electrochemical Society*, 2004, 151(11): A1977-A1988.
- [17] YU Q, XIONG R, LIN C, et al. Lithium-ion battery parameters and state-of-charge joint estimation based on H-infinity and unscented Kalman filters[J]. *IEEE Transactions on Vehicular Technology*, 2017, 66(10): 8693-8701.
- [18] KIM IL-S. A technique for estimating the state of health of lithium batteries through a dual-sliding-mode

- observer[J]. IEEE Transactions on Power Electronics, 2010, 25(4): 1013-1022.
- [19] HU X, JIANG J, CAO D, et al. Battery health prognosis for electric vehicles using sample entropy and sparse Bayesian predictive modelling[J]. IEEE Transactions on Industrial Electronics, 2015, 63(4): 2645-2656.
- [20] HE W, WILLIAR N, OSTERMAN M, et al. Michael Prognostics of lithium-ion batteries based on Dempster-Shafer theory and the Bayesian Monte Carlo method[J]. Journal of Power Sources, 2011, 196(23): 10314-10321.
- [21] LIN H A, LIAN T J, CHEN S M. Estimation of battery state of health using probabilistic neural network[J]. IEEE Transactions on Industrial Informatics, 2013, 9(2): 679-685.
- [22] SINGH P, FENNIE J C, REEISNER D. Fuzzy logic modelling of state-of-charge and available capacity of nickel/metal hydride batteries[J]. Journal of Power Sources, 2004, 136(2): 322-333.
- [23] NUHIC A, TERZIMEHIC T, SOCZKA-GUTH T, et al. Health diagnosis and remaining useful life prognostics of lithium-ion batteries using data-driven methods[J]. Journal of Power Sources, 2013, 239: 680-688.
- [24] WENG C, FENG X, SUN J, et al. State-of-health monitoring of lithium-ion battery modules and packs via incremental capacity peak tracking[J]. Applied Energy, 2016, 180: 360-368.
- [25] BLOOM I, JANSEN A N, ABRAHAM D P, et al. Differential voltage analyses of high-power, lithium-ion cells: 1. Techniques and application[J]. Journal of Power Sources, 2005, 139(1-2): 295-303.
- [26] WU B, YUFIT V, MERLA Y, et al. Differential thermal voltammetry for tracking of degradation in lithium-ion batteries[J]. Journal of Power Sources, 2015, 273: 495-501.
- [27] ZHANG Y, XIONG R, HE H, et al. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries[J]. IEEE Transactions on Vehicular Technology, 2018, 67(7): 5695-5705.
- [28] YU Z, XIAO L, LI H, et al. Model parameter identification for lithium batteries using the coevolutionary particle swarm optimization method[J]. IEEE Transactions on Industrial Electronics, 2017, 64(7): 5690-5700.
- [29] LI H, PAN D, CHEN C P. Intelligent prognostics for battery health monitoring using the mean entropy and relevance vector machine[J]. IEEE Transactions on Systems Man and Cybernetics-Systems, 2014, 44(7): 851-862.
- [30] YAO L, WANG Z, MA J. Fault detection of the connection of lithium-ion power batteries based on entropy for electric vehicles[J]. Journal of Power Sources, 2015, 293: 548-561.
- [31] SHI B, ZHANG Y, YUAN C, et al. Entropy analysis of short-term heartbeat interval time series during regular walking[J]. Entropy, 2017, 19(10): 568.
- [32] SHERSTINSKY A. Fundamentals of recurrent neural network (RNN) and long short-term memory (LSTM) network[J]. Physica D: Nonlinear Phenomena, 2020, 404: 132306.
- [33] RAHMAN M A, ANWAR S, IZADIAN A. Electrochemical model parameter identification of a lithium-ion battery using particle swarm optimization method[J]. Journal of Power Sources, 2016, 307: 86-97.
- [34] ZHOU D, ZHENG W, FU P, et al. Research on online estimation of available capacity of lithium batteries based on daily charging data[J]. Journal of Power Sources, 2020, 451: 227713.
- [35] ZHENG Y, WANG J, QIN C, et al. A novel capacity estimation method based on charging curve sections for lithium-ion batteries in electric vehicles[J]. Energy, 2019, 185: 361-371.

作者简介: 张朝龙, 男, 1982 年出生, 博士, 教授。主要研究方向为动力电池测试技术, 故障诊断和预测。

E-mail: zhangchaolong@126.com

赵锦筛, 男, 1997 年出生。主要研究方向为动力电池管理技术。

E-mail: zhaoshaishai@126.com

何怡刚(通信作者), 男, 1966 年出生, 教授, 博士研究生导师。主要研究方向为模拟和混合集成电路设计、测试与故障诊断、智能电网技术、射频识别技术、虚拟仪器和智能信号处理。

E-mail: 18655136887@163.com