



储能科学与技术

Energy Storage Science and Technology

ISSN 2095-4239, CN 10-1076/TK

《储能科学与技术》网络首发论文

题目: 模型与数据双驱动的锂电池状态精准估计
作者: 陈清扬, 何映晖, 余官定, 刘铭扬, 徐翀, 李振明
DOI: 10.19799/j.cnki.2095-4239.2022.0508
收稿日期: 2022-09-07
网络首发日期: 2022-10-08
引用格式: 陈清扬, 何映晖, 余官定, 刘铭扬, 徐翀, 李振明. 模型与数据双驱动的锂电池状态精准估计[J/OL]. 储能科学与技术.
<https://doi.org/10.19799/j.cnki.2095-4239.2022.0508>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。



收稿日期：2022-09-07；修改稿日期：2022-09-23。

模型与数据双驱动的锂电池状态精准估计

陈清扬¹，何映晖²，余官定³，刘铭扬⁴，徐翀⁵，李振明⁶
(¹⁻³浙江大学 信息与电子工程学院，浙江 杭州 310058；⁴⁻⁶中国电力科学研究院储能与电工新技术研究所，北京 100192)

摘要：针对电池荷电状态估计常用的模型驱动法与数据驱动法的缺点，本文提出了一种模型与数据双驱动的锂电池状态精准估计算法。在建立经典二阶电池模型后，先使用扩展卡尔曼滤波器与无迹卡尔曼滤波器组成的双卡尔曼滤波器进行初步的锂电池系统状态估测，再将初步的估算结果输入 LSTM 神经网络实现误差纠正，得到最终估测结果。本文利用来自 NASA PCoE 的电池数据集对单驱动算法和双驱动算法分别进行了性能测试，结果表明双驱动法在降低了估算系统对数据依赖性的同时提高了估算精度以及算法鲁棒性，结合了两种单驱动法的优点并弥补了各自的缺点，得到了较为优异的结果。

关键词：锂电池；电池荷电状态；电池健康状态；模型驱动法；数据驱动法；扩展卡尔曼滤波；无迹卡尔曼滤波；LSTM 神经网络

doi: 10.19799/j.cnki.2095-4239.2022.0508

文献标志码：A

文章编号：2095-4239 (XXXX) XX-1-09

Integrating model-driven and data-driven methods for accurate state estimation for lithium-ion batteries

CHEN Qing-yang¹, HE Ying-hui², YU Guan-ding³, LIU Ming-yang⁴, XU Chong⁵, LI Zhen-ming⁶
(¹⁻³College of Information and Electronic Engineering, Zhejiang University, Hangzhou 310058, China; ⁴⁻⁶Energy Storage and Novel Technology of Electrical Engineering Department, China Electric Power Research Institute, Beijing 100192, China)

Abstract: Aiming at the shortcomings of the commonly used model-driven method and data-driven method for battery state-of-charge estimation, an integrating method of model-driven and data-driven for accurate state estimation for lithium-ion batteries are proposed. After establishing the classical second-order battery model, a dual-Kalman filter composed of an extended Kalman filter and an unscented Kalman filter was used to preliminarily estimate the status of the lithium battery system. Then, the preliminary estimation results were input into the LSTM neural network to correct the errors and therefore complete the data-driven part. Dataset from NASA PCoE were used to test the performance of the single-driven method and the dual-driven method. Results show that the integrating method reduces the dependence of the estimation system on the data while improving the estimation accuracy and robustness, since it combines the advantages of the model-driven method and data-driven method and makes up for their shortcomings. Satisfactory result are obtained.

Keywords: lithium battery; state of charge; state of health; model-driven method; data-driven method; extended Kalman filter; unscented Kalman filter; long-short-term neural network

1 引言

锂电池由于具有循环电池寿命相对长、自放电量较少、无记忆性问题等优势,对我国新能源的发展与普及具有重要意义。根据中国中关村储能行业科技联盟对全球储能项目数据库的调研报告,截至二零一九年六月,全球上实际存在的蓄积于锂离子或动力电池能量储备项目的比重已经超过了总电化学能量储备的 86%^[1]。随着锂电池的大面积普及,其本身的性能、利用率及安全性成为了业界最为关注的重点之一。

健康状况 (State of Health,SOH)、荷电状况 (State of Charge,SOC)、开路电压 (Open Circuit Voltage,OCV)是用于判断锂电池状态是否正常的最主要的参数。值得注意的是,SOC 无法直接检测,它与可被测得的电池参数(包括开路电压、工作电流、电池内部温度等)间不存在线性关系,所以对于锂离子电池中 SOC 值的精确预测是业界研究的主要难点之一^{[2]-[3]}。

如今较为常见的电池 SOC 估测算法可分为直接估计法、模型驱动法与数据驱动法三类。直接估计法包括库伦计数法和开路电压法极易受到环境噪声和测量限制的影响,实用性较差^{[4]-[7]}。相较于此,现有较为优越的两类 SOC 估测方法——模型驱动法和数据驱动法在稳定性、收敛性和预测精度上都有了显著的提高。模型驱动法以卡尔曼滤波^[8]为代表,在一定程度上降低了系统的开环风险,但若仅使用模型驱动法,电池模型本身的不精确性会大大影响 SOC 估算的精确度,同时电池充放电状态在使用过程中充满随机性,观测量的频繁突变进一步放大了模型驱动法的不稳定性。数据驱动法以神经网络、模糊逻辑^{[9]-[10]}为代表,在简化电池建模过程的同时保证了算法鲁棒性,但其忽略了系统的开环风险,对于选用的电池状态参数类别、数量、训练方式等都有着极高的要求,因此需要较高的训练成本才能确保其收敛性。

现有的大多数 SOC 估测方法采用了模型驱动与数据驱动中的一种,通过将基本的卡尔曼滤波器或神经网络不断复杂化以实现个别算法指标的改进,却无法综合提升算法的估计精度、收敛性、鲁棒性、模型泛化和其他指标方面的全面性能。因此,针对以往算法的片面性,本文提出了基于模型与数据双驱动的 SOC 估测算法,实现了算法综合性能的提高。

本文主要贡献主要如下:

- 1、明确采用模型驱动与数据驱动的串联融合,在保证精度的同时提升算法的鲁棒性。
- 2、创新使用扩展卡尔曼滤波器与无迹卡尔曼滤波器这一组合分别处理 SOC 估计中线性程度不同的部分,提升模型驱动法结果的可信度。
- 3、使用 LSTM 神经网络完成数据驱动法部分,以贴合电池状态具有时序性的特点。

在完成算法设计与搭建后,本作采用来自 NASA 卓越中心的电池数据集对单驱动法、双驱动法分别进行测试,以证实双驱动法的优越性。

2 锂电池等效模型

由于本文算法涉及模型驱动模块,因此需提前建立锂电池等效模型,其精度会极大地影响模型驱动法的性能。

电池等效模型通常可分为电化学模型和等效电路模型二类。通常,电化学模型在模拟电池状态时比后者更精确,然而实操难度较大。与传统电化学模型相比,等效电路模型简单,性能良好。因此,它被认为是最适合估算 SOC 的模型之一^[11]。N 阶 RC 模式也是最常见的等效电路模式之一,拥有着精度高等优点。它有 n 个电阻-电容分支,每个分支由一个电阻器和一个电容器组成。然而在实际的仿真模拟过程中,对等效电路模型中无限的 RC 网络进行计算分析是不现实的,简化模型是必要的。已有对一阶到四阶的 RC 等效电路模型进行了仿真试验^[12],发现一阶模型的拟合误差明显较大,而二、三和四阶模型误差相差不大。其原因可能是电池内部的电化学反应随着电池老化越来越复杂,简单的一阶模型已经难以拟合,而高阶模型对复杂的非线性过程有更好的拟合能力。为了便于实际计算,本文将以二阶 RC 等效电路模型为例进行分析。

二阶 RC 等效电路模型结构如图 1 所示,我们假设两个 RC 并联网络两端的电压差分别为 U_1 、 U_2 。




图 1 2-RC 电池等效模型

Fig.1 2-RC electric equivalent circuit model of battery

3 模型与数据双驱动的 SOC 估测算法

3.1 算法流程

3.1.1 双驱动联合模式

由于本研究中电池模型并不精确,相关参数确切简洁,需同时追求估测的实时性和准确性,因此采用较为灵活的串联法来实现双驱动集成。

模型与数据双驱动的联合模式主要可分为串联法、并联法与融合法三种^[13]。本文采取的串联法流程如图 2 所示,其先后利用两种驱动方式对数据进行处理,输出最终结果。在实际应用过程中,也可以使用模型驱动方式为数据驱动方法筛选关键特性,这样就可以降低数据驱动方法的输入特性维度。数据驱动方法也可用作模型驱动方法的误差校正方法。该方法可以提高准确性、时间效率和灵活性。




图 2 串联法流程示意图

Fig.2 Schematic diagram of serial integration approach

3.1.2 双驱动 SOC 估测算法流程

首先利用模型驱动模块对电池数据进行处理输出大致的 SOC 估计结果,再将该结果及原始数据输入数据驱动模块实现误差修正输出最终结果。

利用 SOC 的初步估测数据以及两个卡尔曼滤波器的观测误差值,神经网络可以拟合出初步数据、误差值与最终参考值之间的某种非线性拟合关系,从而实现初步数据的误差纠正,使其更接近真实值。另外, LSTM 神经网络中加入了温度这一特征,从而涉及到了模型驱动法中并没有计算到的部分,更有利于精度的提升。

总体算法流程如图 3 所示。

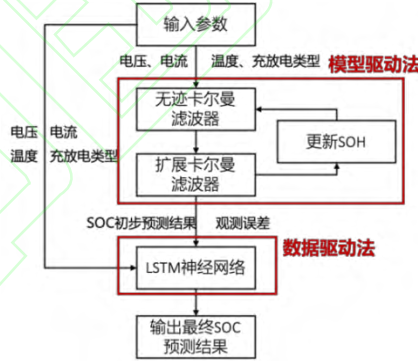


图 3 双驱动算法流程图

Fig.3 Schematic diagram of dual-driven algorithm

3.2 模型驱动模块

3.2.1 扩展卡尔曼滤波器

锂电池模型是一个经典的非线性系统,然而传统的卡尔曼滤波器仅能用来解决线性问题,无法应付锂电池 SOC 这一非线性相关的特征,因此我们使用到了扩展卡尔曼滤波器^[14]。扩展卡尔曼滤波器(Extended Kalman Filter, EKF)广泛应用于非线性系统的预判。EKF 的基本原理是对状态函数和测量函数执行一阶的泰勒展开,从而使得其局部线性化。对于非线性系统,可以使用以下状态空间方程来描述:

$$\begin{cases} \mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}) + \mathbf{w}_{k-1} \\ \mathbf{y}_k = h(\mathbf{x}_k, \mathbf{u}_k) + \mathbf{v}_k \end{cases} \quad (1),$$

式中, \mathbf{x}_k 是系统状态变量; \mathbf{y}_k 则是系统观测变量; \mathbf{u}_k 则是系统输入变量; f 是状态的非线性函数; h 是观测的非线性函数; \mathbf{w}_{k-1} 和 \mathbf{v}_k 分别是均值为零和协方差为 \mathbf{Q} 和 \mathbf{R} 的高斯白噪声。

在使用 EKF 估计状态时,需要提供精准的先验噪声统计结果,包括过程噪声方差矩阵 \mathbf{Q} 和测量噪声方差矩阵 \mathbf{R} 。不准确的 \mathbf{Q} 与 \mathbf{R} 会导致 EKF 的计算准确度降低。如果 \mathbf{Q} 和 \mathbf{R} 太小,不确定性范围将太小,从而

导致估计有偏差。如果 \mathbf{Q} 和 \mathbf{R} 太大,可能会导致过滤器发散。另外, EKF 假设 \mathbf{Q} 和 \mathbf{R} 为常数,而在实际滤波过程中,电池模型会受到干扰。此时,应估计模型扰动后的 \mathbf{Q} 与 \mathbf{R} 的值,然后调整滤波器增益矩阵 \mathbf{K} 。

3.2.2 无迹卡尔曼滤波器

无迹卡尔曼滤波器^[15](Unscented Kalman Filter, UKF)是典型的通过无迹变换进行递归状态估计的滤波方法。无迹变换方法既可通过几个已知的 σ 点捕捉 Gaussian 分布的均值和方差,还可在使用基于传播的 σ 点的非线性系统同时捕捉随机变量的后验分布。UKF 算法使用一组特定样本的近似概率密度分布,从而拟合状态的后验概率密度,不需要计算 Jacobi 矩阵。因此, UKF 不会与 EKF 一样在强非线性系统中增加估计误差,导致估计精度不理想。

3.2.3 基于双卡尔曼滤波器的模型驱动模块

电池开路电压 OCV 指电池在不连入电路情况下正负极之间的电压大小。研究人员证实,在电池开关压力和电池荷电状态之间具有一个稳定的参数关联,而且这个参数关联并不因为锂电池的使用而改变。因此,在已知 OCV-SOC 曲线的情况下,只需获得 OCV 即可粗略确认电池的荷电状态。

因此,选择 $[U_1 \ U_2 \ SOC]^T$ 作为 UKF 的状态向量,根据 2-RC 等效电路以及戴维南定理列出以下方程组:

$$\begin{cases} i(t) = \frac{U_1(t)}{R_1} + C_1 \frac{dU_1(t)}{dt} \\ i(t) = \frac{U_2(t)}{R_2} + C_2 \frac{dU_2(t)}{dt} \\ SOC(t) = SOC(t_0) - \frac{\eta \int_{t_0}^t i(t) dt}{C_s} \end{cases} \quad (2)$$

式中 C_s 表示电池在满电情况下可存储的电量, η 代表库伦效率,即在相同的充放电的循环中该电池释放的电量与输入的电量的比值。联立方程组并离散化后可得到如下 UKF 状态转移方程:

$$\mathbf{X}_k = \mathbf{A}_{k-1}\mathbf{X}_{k-1} + \mathbf{B}_{k-1}\mathbf{I}_{k-1} + \mathbf{W}_{k-1} \quad (3)$$

其中 \mathbf{X} 为状态向量 $[U_1 \ U_2 \ SOC]^T$;为与电压 \mathbf{U} 区分,此处系统输入(即 $k-1$ 时刻的电流大小)由 \mathbf{I}_{k-1} 表示。

\mathbf{A} 表示系统状态向量, \mathbf{B} 表示系统输入的系数矩阵,具体数值为:

$$\mathbf{A}_{k-1} = \begin{bmatrix} e^{-\frac{\Delta t}{\tau_1}} & 0 & 0 \\ 0 & e^{-\frac{\Delta t}{\tau_2}} & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (4)$$

$$\mathbf{B}_{k-1} = \begin{bmatrix} R_1(1 - e^{-\frac{\Delta t}{\tau_1}}) \\ R_2(1 - e^{-\frac{\Delta t}{\tau_2}}) \\ -\frac{\eta \Delta t}{C_s} \end{bmatrix} \quad (5)$$

式中 τ_1 、 τ_2 为 2-RC 电路中两个阻容并联结构的时间常数。

将电池正负极两端电压差作为系统观测量,则锂电池的观测方程为:

$$Z_k = U_k = U_{OCV}(SOC_k) - i_k R_0 - U_{1,k} - U_{2,k} + V_k \quad (6)$$

式中 $U_{OCV}(SOC_k)$ 表示由 SOC 映射至 OCV 的函数关系。设 R_0 为 EKF 的状态向量。由于数据采集频率较高,可忽略锂电池内阻的变化,因此 EKF 的状态转移方程为

$$\mathbf{X}_k = \mathbf{X}_{k-1} \quad (7)$$

同样将电池正负极电压差作为 EKF 观测量,观测方程与前文一致。

基于双卡尔曼滤波器的模型驱动算法具体流程如图 4 所示。

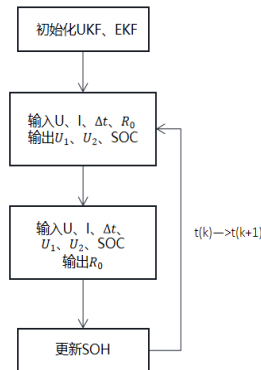


图 4 双卡尔曼滤波器算法流程图

Fig.4 Schematic diagram of dual-Kalman filter algorithm

在初始化卡尔曼滤波器后，可通过 UKF 对电池的荷电状态和极化电压进行预测，并将此结果作为 EKF 的输入，以更新对电池内阻的估计。在 EKF 算法完成后更新电池满电状态下的电荷量 C_s 。因为电池 SOH 值与电池内部阻抗间具有一一对应关系，因此可利用电池内部阻抗计算 SOH，具体表达式如下：

$$SOH = \left| \frac{R_{old} - R_{test}}{R_{old} - R_{new}} \right| \times 100\% \quad (8)$$

得到 SOH 后可根据其定义以及电池生产时的满电状态下储存的电量计算得出 C_s ，完成一个计算周期。再次采样获得数据后，不断循环上述步骤，从而实现对锂电池各个状态参数的实时估算。

3.3 数据驱动模块

3.3.1 LSTM 神经网络

循环神经网络（Recurrent neural network，RNN）的实际训练流程中，由于同时添加了一系列数据，来自早期时刻的信息对当前时刻的输出几乎没有影响。另外，RNN 的一个缺陷就是序列中稳定性的显著降低，在反向扩散过程中很容易发生梯度消失或梯度爆炸。作为 RNN 的改进版本，LSTM 被引入来解决该问题。

图 5 显示了常用的单个 LSTM 单元，其中 σ 表示 sigmoid 激活函数， \tanh 表示双曲函数； x_k 是一个 1×6 的向量，是整个网络的输入值，包含了第 k 步时电池的电压、电流、温度、双滤波器观测误差、初步 SOC 估计值； h_{k-1} 为前一时间步 $k-1$ 的输出，即对锂电池 SOC 的最终估计值。与 RNN 不同，LSTM 配备了三个门来存储长期依赖关系。输入门、输出门和遗忘门组合在一起，以决定一个单元是否应该记忆或遗忘新获取的信息。具体表达公式如下：

$$\begin{cases} i_k = \sigma(W_{xi}x_k + W_{hi}h_{k-1} + b_i) \\ f_k = \sigma(W_{xf}x_k + W_{hf}h_{k-1} + b_f) \\ c_k = f_k c_{k-1} + i_k \tanh(W_{hc}h_{k-1} + b_c) \\ o_k = \sigma(W_{xo}x_k + W_{ho}h_{k-1} + b_o) \\ h_k = o_k \tanh(c_k) \end{cases} \quad (9)$$

其中 W 表示权重， i 、 f 、 o 和 c 表示进入门、出口门、遗忘门和记忆单元。 b 代表偏置。Sigmoid 函数的门输出值在 0-1 之间，但一旦门的值接近于零，将不是存储了新的输入信号（对于输入门），而是忘记以前的记忆（对于遗忘门），并且过去的记忆不会影响当前输出（对于输出门）。如图 5 所示，每个门层实际上都是一个全连接层。LSTM 单元的其他部分使用 \tanh 函数作为激活函数，因为它的二阶导数在归零之前可以在很长的范围内保持，这可以有效地解决梯度消失问题。

3.3.2 基于 LSTM 神经网络的数据驱动模块

长短期记忆神经网络，简称 LSTM 神经网络，它具有所有 RNN 神经网络都拥有的记忆能力，同时额外配备了遗忘门、输入门和输出门来实现对过去记忆的筛选功能，使其克服了传统 RNN 神经网络的长期依赖问题^[16]。电池状态是随着时间连续发展变化的，因此在对其进行估计时不仅需考虑当前时刻的各参数数值，还需考虑在过去时刻中所测量到的所有性能状态。因此具有记忆功能的 RNN 神经网络有着相较于其他数据驱动方法独一无二的优越性，而 LSTM 更是 RNN 神经网络中性能最为良好的算法之一。




图 5 LSTM 神经网络神经元结构图

Fig.5 Schematic diagram of LSTM neural network

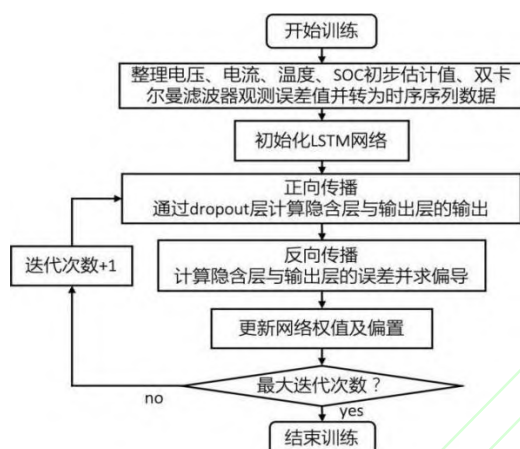


图 6 LSTM 模型训练过程

Fig.6 The training process of LSTM neural network

根据采集到的电池运行状态如电压、电流、温度以及由数据驱动法得出的 SOC 初步估计值、观测误差、电池 SOH 信息构造出符合时序特征的输入数据格式,输入数据是大小为一行六列的矩阵,一行指一个时刻,六列分别指六个电池特征。在利用历史时间信息的形式输入电池特性信息的同时,也将当前时间内特定形式的电池特性信息导入至 LSTM 神经网络,最后计算得到对锂电池当前荷电状态的估算值。LSTM 神经网络的训练结构见图 6,首先通过激活函数为 sigmoid 的 LSTM 网络,而后进入遗忘率为 0.5 的 dropout 层、LSTM 学习层、再一次 dropout 层之后连入全连接网络并最终输出 SOC 估计结果。将每一组训练数据分别代入神经网络模型并不断迭代训练,得到最终的 LSTM 模型,输出最终的 SOC 估测结果。

4 实验

4.1 参数获取

本实验的测试数据来自美国国家航空航天局卓越预报中心的电池测试数据集^[17]。其中记录了四组锂电池在限定电流大小情况下执行特定的充放电操作。充放电操作共分为随机游走模式 (Random Walk, RW)、参考充放电、脉冲充放电 (Pulse)、低电流放电。电池中设有传感器以一定频率测量电池的电压、电流、温度、充放电持续时间、充放电模式等信息。

建立电池物理模型后,有部分参数需要提前计算获取以确保后续算法的运行。获得参数的精度会极大影响算法的准确性。

首先是 OCV-SOC 对应曲线。目前常用的拟合方法包括复合模型法、多项式拟合法等。传统精确测量电池开路电压的方法要求电池在放电后长时间静置以消除电池内部极化效应产生的压降。该方法效率极低,采样一组数据便需要几个小时的时间。由于锂电池内阻较小,可采用小电流放电的方式来辅助确认 OCV-SOC 曲线,在同样耗时的情况下可采集多组开路电压数据,此时电池内部的压降为毫伏级别,在大多应用场景中可忽略不计。因此,利用小电流法拟合的 OCV-SOC 关系曲线如图 7 所示。

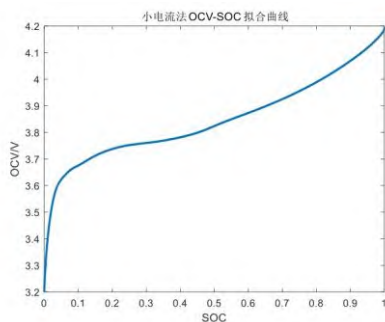


图 7 小电流法 OCV-SOC 对应曲线

Fig.7 OCV-SOC corresponding curve

除此之外,面对非线性拟合问题,采用神经网络更不失为一种更好的选择。本实验使用了传统的 BP 神经网络实现拟合。神经网络拟合结果,如图 8 所示。

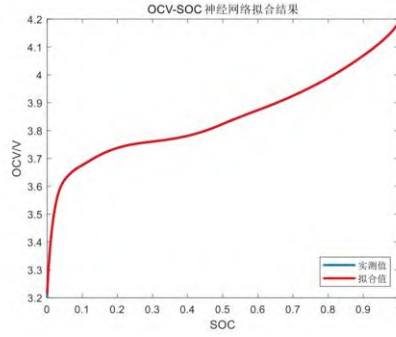


图8 BP神经网络拟合 OSV-SOC 对应曲线

Fig.8 OCV-SOC corresponding curve

其次是电池 2-RC 等效电路模型的相关参数，包括两个 RC 并联网路的时间常数 τ_1 、 τ_2 以及极化电阻 R_1 、 R_2 。已知测试用锂电池脉冲放电曲线如图 9 所示，且满足以下等式：




图9 卡尔曼滤波器观测误差

Fig.9 Absolute error of observations of Kalman filters

$$U(t) = U_{OCV}(t_D) - U_1 e^{-\frac{t-t_D}{\tau_1}} - U_2 e^{-\frac{t-t_D}{\tau_2}} \quad (10)$$

$$U(t) = U_{OCV}(SOC_t) - i(t)R_0 - i(t)R_1(1 - e^{-\frac{t-t_0}{\tau_1}}) - i(t)R_2(1 - e^{-\frac{t-t_0}{\tau_2}}) \quad (11)$$

利用最小二乘法将涉及数据代入方程可计算得到所需模型参数。

上述参数以及电池欧姆内阻 R_0 、库伦效率 η 的结果汇总如表 1 所示。

表 1 电池模型参数数据汇总

Tab.1 Parameters of equivalent model of battery

参数名	参数值
η	0.991
τ_1	210.056
τ_2	28.185
R_0	75m Ω
R_1	76.3m Ω
R_2	28.3m Ω

4.2 恒电流脉冲放电数据测试

本文利用恒流脉冲放电与随机充放电两组数据分别对单模型驱动法以及模型-数据双驱动进行了测试。为避免电池在长期充放电后 SOH 变化带来的误差，本实验选择在完成参考充放电测量后最邻近的 Pulse

类型数据和 Random Walk 数据进行测试。利用参考充放电数据获得电池当前满电状态下可储存的电荷量 C_s ，并使用（32）所示的安时积分法，代入 Pulse 阶段的测试数据从而得出实际 SOC，为后续估计提供参考。

$$SOC(k) = SOC(k-1) - \eta \int_{t_{k-1}}^{t_k} \frac{i(t)}{C_s} dt \times 100\% \quad (12)$$

首先使用脉冲充放电数据对算法进行实验。该阶段数据采样间隔为 1s，共 20000 个数据。分别使用双驱动法、模型驱动法、数据驱动法对 SOC 进行预测，其中由模型驱动模块得到的双卡尔曼滤波器观测误差如图 9 所示，预测绝对误差结果如图 10-11 所示。可以发现，单纯使用模型驱动模块在 SOC 值较大时能得到较为满意的结果，估测绝对误差保持在 ± 0.01 以内，相对误差保持在 $\pm 3\%$ 左右。在 SOC 小于 0.4 后，估测误差会大幅上升，相对误差在 0.02 左右。单纯使用数据驱动法对 SOC 的估测效果不佳，不论 SOC 大小如何，误差在均 ± 0.15 以上，原因为数据特征较少，神经网络的训练结果难以收敛。双驱动法在精确度上相较于两者均有较为明显的提升，在 SOC 较大的情况下，误差可维持在 ± 0.005 以内；在 SOC 较小的情况下，通过神经网络的误差纠正，误差也可维持在 ± 0.01 左右。

以上对恒电流脉冲充放电数据集的估测结果汇总如表 2 所示，误差 CDF 分布情况如图 12 所示。

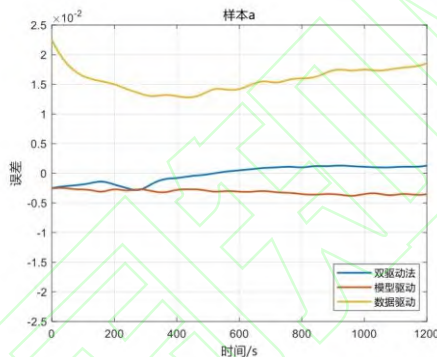


图 10 恒电流充放电 SOC 估测绝对误差 (SOC>0.4)
Fig.10 Pulse charge SOC estimation absolute error (SOC>0.4)

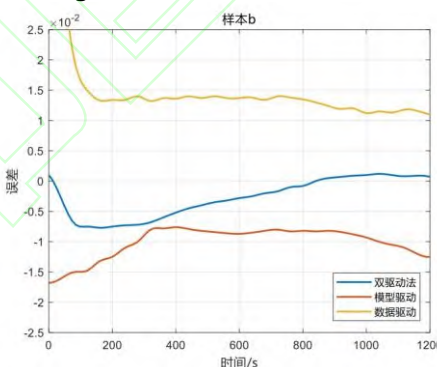


图 11 恒电流充放电 SOC 估测绝对误差 (SOC<0.4)
Fig.11 Pulse charge SOC estimation absolute error (SOC<0.4)

表 2 恒电流充放电 SOC 估测误差

Tab.2 Pulse charge SOC estimation error

估测方法	估测参数	绝对误差	相对误差
模型驱动法	SOC (大于 0.4)	± 0.01	$\pm 3\%$
模型驱动法	SOC (小于 0.4)	0.02+	/
数据驱动法	SOC	0.015+	/
双驱动法	SOC (大于 0.4)	± 0.005	$\pm 1.5\%$
双驱动法	SOC (小于 0.4)	± 0.01	/

4.3 随机游走充放电数据测试




图 12 恒电流充放电 SOC 估测绝对误差概率分布图
Fig.12 CDF of pulse charge SOC estimation absolute error

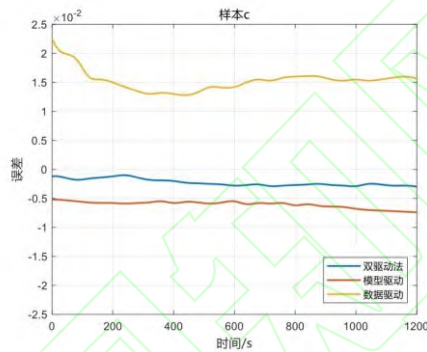


图 13 随机充放电 SOC 估测绝对误差 (SOC>0.4)
Fig.13 Random Walk SOC estimation absolute error (SOC>0.4)

首先单纯利用模型驱动模块对随机充放电数据进行预测。数据采样间隔为 1 秒，共 24000 个数据。分别使用双驱动法、模型驱动法、数据驱动法对 SOC 进行预测，预测绝对误差结果如图 12-13 所示。模型驱动法的 SOC 估测绝对误差维持在 ± 0.02 之间，在 SOH 大于 0.4 时，相对误差保持在 5%-7%左右，当 SOH 小于 0.4 后误差会大幅度上升，相对误差甚至会达到 0.02+。由以上数据可发现，Random Walk 阶段的模型驱动法估测精度以及鲁棒性较差，说明了单模型驱动法易受突变因素影响而不稳定的特点。单纯使用数据驱动法对 SOC 的估测效果不佳，不论 SOC 大小如何，误差均在 ± 0.15 以上，原因为数据特征较少，神经训练结果难以收敛。




图 14 随机充放电 SOC 估测绝对误差 (SOC<0.4)
Fig.14 Random Walk SOC estimation absolute error (SOC<0.4)

当 SOC 小于 0.4 时，双驱动法的相对误差也会有所上升，但绝对误差维持在 ± 0.015 以内，相较单驱动法也有所提升。说明在模型和数据驱动的相辅相成下，模型驱动法帮助数据驱动法更好的收敛，降低了数据依赖性；数据驱动法帮助模型驱动法修正了误差，提高了算法总体的鲁棒性。

以上对随机游走充放电数据集的估测结果汇总如表 3 所示，误差 CDF 分布情况如图 15 所示。

表 3 随机充放电 SOC 估测误差

Tab.3 Random Walk SOC estimation error

估测方法	估测参数	绝对误差	相对误差
------	------	------	------

模型驱动法	SOC (大于 0.4)	± 0.02	$\pm 7\%$
模型驱动法	SOC (小于 0.4)	0.02+	/
数据驱动法	SOC	0.015+	/
双驱动法	SOC (大于 0.4)	± 0.01	$\pm 2\%$
双驱动法	SOC (小于 0.4)	± 0.015	/

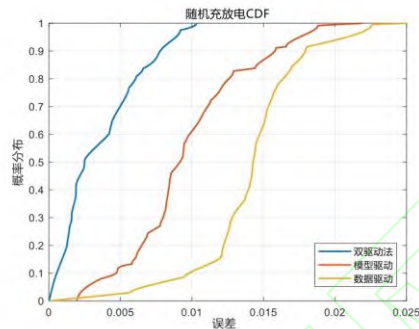


图 15 随机充放电 SOC 估测绝对误差概率分布图
Fig.15 CDF of Random Walk SOC estimation absolute error

5 结论

本文首先讨论了传统 SOC 估测方法，总结提炼出了模型驱动法与数据驱动法的优劣并进行了有机结合，通过串联使用的方式得到了一种模型与数据双驱动的 SOC 估测方式。实验结果表明，新算法在提高模型驱动法精度的同时降低了数据驱动法对于数据的依赖，相较于单模型驱动法、单数据驱动法具有更高的精确度以及算法鲁棒性。双驱动融合算法具有较高的研究价值，本文仅探讨了串联使用模型驱动法与数据驱动法的方式来估测电池健康状况。倘若能建立更加精准的电池等效电路模型，融合使用双驱动法不失为一种值得考虑的选择。最后，目前电池爆炸事故频发，为避免类似悲剧的发生，仅仅预测电池 SOC、SOH 是远远不够的。BMS 需要搭载更多电池健康参数的预测系统，例如电池压力、电池内化学离子浓度、泄露气体浓度等等，从而起到更好的预警作用。

参考文献 (References)

- [1] 宁娜.2019 上半年中国储能十大事件回顾[J].能源,2019(09):28-32.
Na Ning. Review of top ten events in China's energy storage in the first half of 2019 [J]. Energy, 2019(09): 28-32.
- [2] Yao He,XingTao Liu,ChenBin Zhang,ZongHai Chen. A new model for State-of Charge(SOC) estimation for high-power Li-ion batteries. Applied Energy, 2013,101.
- [3] 冯飞,宋凯,逯仁贵,魏国,朱春波.磷酸铁锂电池组均衡控制策略及荷电状态估计算法[J].电工技术学报,2015,30(01):22-29.
Fei Feng, Kai Song, Guo Wei, et al. Balance control strategy and state of charge estimation algorithm of lithium iron phosphate battery pack [J]. Journal of Electrotechnical Technology, 2015, 30(01): 22-29.
- [4] Languang, Lu,Xuebing. Han,Jianqiu Li,Jianfeng Hua,Minggao Ouyang. A review on the key issues for lithium-ion battery management in electric vehicles. Journal of Power Sources, 2013,226.
- [5] Lucian Ungurean,Gabriel Cârstoiu,Mihai V. Micea,Voicu Groza. Battery state of health estimation: a structured review of models, methods and commercial devices. International Journal of Energy Research, 2017,41(2).
- [6] Matthieu Dubarry, Vojtech Svoboda, Ruey Hwu, Bor Yann Liaw. Capacity loss in rechargeable lithium cells during cycle life testing: The importance of determining state-of-charge. Journal of Power Sources,2007,174(2).
- [7] 孙冬,许爽.梯次利用锂电池健康状态预测[J].电工技术报,2018,33(09):2121-2129.
Dong Sun, Shuang Xu, Prediction of the health state of lithium battery for cascade utilization[J]. Electrotechnical Journal, 2018, 33(09): 2121-2129.
- [8] Cai Y , Wang Q , Qi W . D-UKF based state of health estimation for 18650 type lithium battery. 2016 IEEE International Conference on Mechatronics and Automation. IEEE, 2016.
- [9] Hussein, A.A. Capacity fade estimation in electric vehicles Li-ion batteries using artificial neural networks. Energy Conversion Congress & Exposition. IEEE, 2013.
- [10] Dave Andre,Christian Appel,Thomas Soczka-Guth,Dirk Uwe Sauer. Advanced mathematical methods of SOC and SOH estimation for lithium-ion batteries. Journal of Power Sources, 2013,224.
- [11] Micea M V , Ungurean L , Carstoiu G N , et al. Online state-of-health assessment for battery management systems[J]. Instrumentation and Measurement, IEEE Transactions on, 2011, 60(6):p.1997-2006
- [12] 许巧巧. 锂离子动力电池剩余容量估计算法研究与实现[D].重庆大学,2013
Qiaoqiao Xu, Research and implementation of estimation algorithm for remaining capacity of Li-ion power battery [D]. Chongqing University, 2013
- [13] Qi Wang, Feng Li, Yi Tang, Yan Xu. Integrating model-driven and data-driven methods for power system frequency stability assessment control". IEEE Transactions on power systems, Vol.34, NO. 6, November 2019
- [14] Ribeiro M I. Kalman and extended kalman filters: Concept, derivation and properties[J]. Institute for Systems and Robotics, 2004, 43: 46

- [15] Wan E A, Van Der Merwe R. The unscented Kalman filter for nonlinear estimation[C]//Proceedings of the IEEE 2000 Adaptive Systems for Signal Processing, Communications, and Control Symposium (Cat. No. 00EX373). Ieee, 2000: 153-158.
- [16] 林成涛,王军平,陈全世.电动汽车 SOC 估计方法原理与应用[J]电池,2004(05) 376-378.
Chengtao Lin, Junping Wang, Quanshi Chen, Principle and application of electric vehicle SOC estimation method [J] Battery, 2004(05) 376-378.
- [17] Bole B , Kulkarni CS , Daigle M . Adaptation of an electrochemistry-based Li-Ion battery model to account for deterioration observed under randomized use[C]// Conference of the Prognostics & Health Management Society.

