

锂离子电池状态估计机器学习方法综述*

谢奕展,程夕明

(北京理工大学机械与车辆学院, 电动车辆国家工程试验室, 北京 100081)

[摘要] 本文旨在综述机器学习方法在锂离子电池状态(包括荷电状态、健康状态和剩余可用寿命)估计领域的研究进展。首先,阐述机器学习方法在电池状态估计中的应用现状。然后,归纳电池状态估计机器学习方法的5个具体实施环节,即数据准备、模型选择与评价、超参数确定、数据预处理和模型训练,并提出了融合精度、实施成本和鲁棒性的学习算法评价方法。最后指出超参数确定方法仍存在的场景适应性问题,并建议建立多区域、跨季节、多模式和长时间的车用电池工况数据库,促进电池状态估计机器学习算法的实用性和普适性等方面的研究。

关键词: 锂离子电池;机器学习;荷电状态;健康状态;剩余寿命

Review of State Estimation of Lithium-ion Battery with Machine Learning

Xie Yizhan & Cheng Ximing

School of Mechanical Engineering, National Engineering Lab for Electric Vehicles, Beijing Institute of Technology, Beijing 100081

[Abstract] This paper aims to give a comprehensive review on the research progress in the field of the estimation of the states of lithium-ion battery, including the state of charge (SOC), state of health (SOH) and residual useful life (RUL). Firstly, the application status of machine learning method to the estimation of battery states are expounded. Then, five specific implemental links of machine learning methods for battery state estimation are summarized, including data preparation, model selection and evaluation, hyperparameter determination, data preprocessing and model training, and an evaluation method of learning algorithms is proposed in terms of fusion accuracy, implementation cost and robustness. Finally, the problem of scene adaptability in determining hyperparameters is pointed out, with a suggestion put forward: establishing multi-regional, cross-seasonal, multi-mode and long-term driving cycle database of traction battery, so as to promote the research on the practicability and universality of machine learning algorithms for battery state estimation.

Keywords: lithium-ion battery; machine learning; SOC; SOH; RUL

前言

锂离子电池高能量密度和低成本技术的快速发展促进了电动汽车的市场化步伐,而电池管理系统的基本功能之一,是对电池的诸多状态进行准确的估计,包括电池的荷电状态SOC、健康状态SOH和剩余使用寿命RUL^[1-2]。

目前,蓄电池的SOC估计、SOH估计和RUL预测的方法主要有基于模型的方法和数据驱动方法两类。基于模型的SOC估计方法有安时积分法^[3]、开路电压法^[4]和等效电路模型法^[5]等。累积误差、长时间静置和等效电路模型参数非线性时变等问题使基于模型的电池状态估计方法的应用受到限制。基于模型的SOH估算方法有实验测量法^[6-7]、差分法^[8]、等效电路模型^[9]和电化学模型^[10]等。其中,实验测

* 国家重点研发计划(2018YFB0106104)资助。

原稿收到日期为2021年5月24日,修改稿收到日期为2021年7月1日。

通信作者:程夕明,副教授,工学博士,E-mail:cxm2004@bit.edu.com。

量法直接对电池容量、内阻和阻抗谱进行测量,这些参数测量的车载条件稳定性差,缺乏可比性。差分法建立蓄电池的容量电压微分曲线峰值与SOH的函数关系,要求测量数据的电流倍率小,易受噪声污染。等效电路模型法通过参数辨识方法建立模型参数与SOH的映射关系,其普适性尚待研究。基于模型的RUL预测有衰减模型法^[11]、等效电路模型法^[12]等。其中,衰减模型法通过寻找温度、充放电倍率、充放电深度等因素与电池的SOH之间的函数关系,建立电池的容量衰减曲线与循环工况参数的数学表达式,该方法需要大量的蓄电池老化实验,对于在特定条件应用的蓄电池具有一定的可行性。基于电路模型的方法则是通过分析已估算的电池SOH的变化趋势,预测电池RUL。以上两种方法依赖电池SOH估计的可靠性。

锂离子电池是一种高度非线性时变的电化学系统,其内部状态受到SOC、温度、倍率、外力和时间等外部因素的耦合影响,且一个封闭环境的运行状态不易通过外部仪器观测。尽管基于模型的方法具有较为明确的物理意义,但是对高度非线性时变、强耦合和时间跨度大的锂离子电池建模将十分复杂而耗时、专业性强,而且模型的可靠性需要电池行为持续性数据的支持。

电池状态估计的机器学习方法是指采用机器学习算法估计电池状态的数据驱动方法。它具有由于其强大的非线性映射能力,如单层神经网络和径向基神经网络均能以任意精度逼近任意函数^[13-14]。本文将锂离子电池视为一种黑箱系统,运用如RVM、GP、神经网络等机器学习算法,自适应建立蓄电池的电流、电压、温度等可测量数据与其状态SOC、SOH、RUL之间的函数关系^[15-18],无需对蓄电池复杂机理的理解,将主要工作聚焦于对象的数据处理,扩大了从业人员的专业范围,备受业界关注。

1 问题描述与算法应用

1.1 数学表达

机器学习方法旨在建立系统的输入与输出的映射关系。将用于锂离子电池状态预测与估计的系统描述为由离散的状态方程和观测方程组成的表达式,记为

$$x_k = f(x_{k-1}, u_{k-1}, w_{k-1}) \quad (1)$$

$$z_k = h(x_k, u_k, v_k) \quad (2)$$

式中: x_k 为系统中间状态量; z_k 为系统观测量; u_k 为系统输入量; w_k 、 v_k 分别为过程噪声和观测噪声。

机器学习算法旨在习得系统状态函数 f 和观测函数 h ,而噪声 w_k 和 v_k 既可作为已知量,也可作为未知量。系统输入 u_k 通常为蓄电池的温度、电流或电压, z_k 则通常表示蓄电池的状态如SOC、SOH和RUL等。对式(1)和式(2)简化或扩充,便可建立各种机器学习算法的函数表达式。

1.2 SOC估计

用于锂离子电池SOC估计的算法旨在建立温度、电流、电压与SOC的映射关系,既可以是递归算法也可以是非递归算法。记 k 时刻的电流、电压、温度、SOC分别为 I_k 、 U_k 、 T_k 、 SOC_k 。记 $D = \{(u_1, z_1), (u_2, z_2), \dots, (u_k, z_k), \dots, (u_N, z_N)\}$ 为整个数据集,那么系统的输入 $u_k = [I_k, U_k, T_k]$,系统的输出 $z_k = SOC_k$ 。

递归算法旨在寻找输入序列 $\{u_k\}$ 与输出序列 $\{z_k\}$ 的映射关系,而非递归算法则是求得点 u_k 与点 z_k 的一一映射关系。无论是SVR^[19]、BPNN^[20]、ELM^[21]、MLP^[22]和CNN^[23]等非递归算法,还是Elman NN^[24]、NARXNN^[25-26]、LSTM-RNN^[27]等递归算法,都能准确估计电池SOC。它们着重研究数据集划分^[20,23,27-30]、超参数优化^[21,24-26,31]、模型训练加速^[32]、求解器性能比较^[22]、滤波器融合^[33-35]和学习算法融合^[36-37]等。

其中,滤波器融合算法将基于模型的滤波器与机器学习算法融合,提高SOC估计精度,例如基于1阶RC等效电路模型的EKF和BPNN融合算法。由于BPNN有效补偿了EKF在动态工况的SOC估计误差,使相应的RMSE从3.43%减小到0.83%^[33]。

融合多种学习算法也能够提高数据驱动方法的电池SOC估计性能。例如,文献[37]中将增量学习应用于RVM,前一个RVM的相关向量与后一个训练样本训练新的RVM,如此重复进行,每次仅保存相关向量,而摒弃了其它数据,减少了存储空间,其预测效果与总数据集训练的RVM相比,SOC预测精度相近。

1.3 SOH估计

蓄电池SOH估计与SOC估计的不同之处在于SOH是一个长期状态,在几个循环周期内,可以假定其保持不变,这意味着估计SOH的数据驱动算法的数据比SOC更多而复杂。通常情况下,锂离子电池采用稳定的恒流-恒压两段式充电,不同SOH的蓄电池充电电压变化曲线能够呈现出明显的差异

性^[38],因此SOH估计算法的输入量常由蓄电池的充电数据生成。

蓄电池SOC估计采用点对点的数据计算,而SOH估计则为曲线或者面对点的数据计算。SOH的输入量提取通常有两种处理方法,第1种将充电数据整体作为模型的输入,第2种方法以提取充电曲线的特征数据作为模型的输入。因此,蓄电池SOH与SOC估计方法的主要不同之处体现在数据驱动算法的输入处理方法在数据时间、数据量和数据行为存在明显的差异。

非递归算法SVR^[39]、RVM^[40]、BPNN^[41-42]、ELM^[43]、MLP^[44-45]、CNN^[46]、ANFIS^[47]和递归算法LSTM-RNN^[48]都已应用于电池SOH的估计,并侧重于健康因子选择^[39-40,49]、网络训练加速^[42,45-46,48]和算法融合^[50-52]等方面研究。其中,平均放电电压、平均放电温度、充电平均电压、充电平均电流、充电平均温度和等效电路模型参数等都可作为电池SOH估计模型的健康因子。对于算法训练,自编码器常用来降低数据维度,减少算法训练时间^[42,50]。

多个机器学习算法融合用来增强电池SOH估计性能。例如,文献[51]中以多组容量衰减电池的特定区间电量变化为健康因子,输入RF算法,输出相应的SOH,其中模型融合了500个决策树。相比GP,RF算法的SOH估计RMSE和运行时间分别减小了约15%和90%。文献[52]中利用一个大型数据集训练CNN估计SOH,生成模型参数。然后,在另一个小型数据集上继续训练旧模型参数,结果表明重新训练的CNN比原CNN的SOH估计RMSE减小0.6%。

1.4 RUL预测

基于SOH估计,电池的RUL预测是由历史容量衰减规律性预测电池将来容量的变化。当预测的容量到达EOL时,对应的循环次数减去当前已循环的次数即为RUL,因此RUL预测和SOH预测可被划分为蓄电池状态估计的同一类问题。RUL预测方法通常有两类:第1类是以前半段容量衰减数据作为估计算法的训练集;第2类是以SOH估计方法估计前半段循环容量,然后根据估计的前半段循环容量数据作为训练集,用第1类方法同时预测SOH和RUL。

递归算法LSTM-RNN^[53]、GRU-RNN^[54]、NARXNN^[55]和非递归算法SVR^[56]、LSSVM^[57]、RVM^[58]、GP^[59]、RBFNN^[60]、MLP^[61]、CNN^[62]等都已应用于构建电池容量衰减模型,预测电池RUL,侧重于

数据集划分^[56]、数据增强^[57]、超参数优化^[58-60]、输入变量选择^[55,59,62]、模型融合^[60-61]和集成学习^[63-64]。

将滤波器与机器学习融合可增强电池RUL预测的可靠性。例如,文献[60]中以双指数模型作为UKF的观测方程预测RUL,然后以RBFNN补偿UKF的预测误差,与仅采用UKF算法相比,融合算法的电池RUL预测结果少了4个循环。集成学习也能改善电池RUL预测的性能。例如,bagging方法比boosting方法有更高的RUL估计精度,且对数据的离群点不敏感^[63]。

2 算法实施

基于机器学习的数据驱动方法实施过程包括数据准备、模型选择与评价、超参数确定、数据预处理和模型训练等5个环节,这些环节都影响到电池状态估计模型的性能。

2.1 数据准备

机器学习算法的状态估计效果依赖于训练数据,训练数据与实车电池工况越相似,则数据驱动算法输出的结果越可靠。因此,电池实验应能够反映车辆行驶工况的环境温度和电流的随机复杂性,然而诸如世界轻型车行驶工况(WLTC)^[65]和新欧洲循环工况(NEDC)^[66]等典型行车工况仅反映了车速-时间关系。依据工况车速,利用车辆动力学关系计算行车功率,由模型电压可计算实验电池的充放电倍率^[67]。

电池容量衰减测试是SOC估计、SOH估计和RUL预测可靠性验证的前提条件,然而相应电池充放电循环上百千次,实验时间长,比如电池容量衰减实验持续了56周^[68]。因此,许多文献利用已有的电池数据集验证其算法性能,比如NASA PCoE Battery Dataset^[69]、NASA Randomized Battery Usage Dataset^[70]、CALCE Battery Datasets^[71]、Stanford Cycle Life Prediction Dataset^[72]、Stanford Fast-Charging Optimization Dataset^[73]、Oxford Battery Degradation Dataset^[74]和Panasonic 18650PF Li-ion Battery Dataset^[75]等。

为了解决数据驱动算法的大量数据需求而成本过高问题,文献[76]中利用一种生成对抗式神经网络GAN-CLS创建数据,并用于训练LSTM-RNN估计SOC,相应的估计均方误差小于0.0025,且比实验采集数据的方法快50倍。

2.2 模型选择与评价

模型的选择应综合考虑拟合精度、成本和鲁棒性。模型的拟合精度,要求电池状态估计与预测的误差小和置信区间小。模型实施成本可分为训练成本和测试成本,前者指模型利用训练集得到满意结果而耗费的成本,如训练时间和训练设备等;测试成本指模型训练的实际应用成本,例如计算速度、内存大小、程序移植所需成本等。算法的鲁棒性指模型能够在数据存在噪声或异常值等情况下仍能够取得较高的精度,或者对训练数据外的数据仍能保持较高的精度^[77]。

2.2.1 评价指标

模型评价指标常由均方误差、均方根误差、绝对误差、平均绝对误差和平均绝对百分比误差等表示,这些指标越小,模型的性能越好。然而,它们应结合真实值的取值范围进行评价。假设 \bar{y} 落在某个区间的概率为 p ,则该区间称为 p 置信区间,如常用的95%置信区间表示 \bar{y} 落在该区间的概率为95%。 \bar{y} 落在包含 y 的置信区间越小,模型性能越好^[29]。而决定系数(R squared, R^2)^[78]是衡量模型拟合程度的无量纲指标,取值范围为 $-\infty \sim 1$,越接近于1,表明模型的拟合效果越好。记 y 为真实值, \bar{y} 、 \hat{y}_i 分别为平均值和估计值, n 为样本数,相应表达式为

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3)$$

2.2.2 精度

一般而言,数据驱动算法在理论上都能够映射任意函数,但是算法实现的前提是系统输入与输出确实存在函数关系,能够找到相应的具体实现。函数关系的存在与否关键在于数据输入特征的选择,例如不同数据特征使模型估计电池SOH的效果不同。算法实现则取决于数据和模型求解方法,例如RUL估计的训练数据包含的循环数越多,预测精度越高^[78]。算法除了提供点估计外,还应提供置信区间估计。目前,仅有少数算法如RVM和GP等能提供置信区间估计。为此,可通过蒙特卡罗算法为模型结果添加区间估计^[79]。

机器学习模型的精度会有所区别,例如LSTM-RNN、GRU RNN、Elman NN等递归算法的估计和预测精度略高于RVM、SVR、GP、BPNN等非递归算法;LSTM-RNN、GRU-RNN、CNN等深度学习网络具有比传统机器学习算法更高的估计精度。

2.2.3 实施成本

传统机器学习方法由于其固有缺陷,如需要矩阵求逆、支持向量随着数据增长而增长,导致训练和测试成本大幅升高,存在大规模数据的适应性问题。深度学习算法如LSTM-RNN、GRU-RNN、CNN等的训练过程需要显卡进行辅助计算^[23,52],训练时间长,导致训练成本上升。

实际算法必须嵌入硬件运行,因此必须考虑算法的运行时间和内存占用等因素对系统成本的影响。基于NASA和Oxford两个数据集,文献[80]中比较了不同算法估计SOH的训练时间和内存需求,结果表明:GRU-RNN的训练时间分别是GP和SVR的70~130倍和4~5倍,而CNN的训练时间则是GP的6~10倍。对于算法的测试时间,SVR<GP<GRU-RNN<CNN。文献[46]中使用CNN和RVM两个算法估计SOH,结果表明CNN的训练时间是RVM的7.6倍,但RVM的测试时间是CNN的9.8倍,而且RVM的内存需求是CNN的139.1倍。对于SOC估计的算法运行成本,文献[51]中的研究结果表明RF的测试时间是GP的10倍以上,文献[25]的研究结果表明PSO优化中NARXNN的训练时间和测试时间仅为BPNN的20%左右,文献[23]的研究结果表明GRU-RNN、LSTM-RNN和CNN算法的运算时间相当,约为1.4 s。然而,LSTM-RNN和GRU-RNN的每秒浮点运算次数为CNN的1.75倍,说明前两者需占用更多内存才能运行。

2.2.4 鲁棒性

鲁棒性表示算法对电池运行数据的噪声、异常值、测试数据与训练数据的分布不尽相同等情况的适应能力。电池状态估计算法的鲁棒性包括叠加噪声的测试数据的算法性能评估^[81]和同批次电池的实验数据检验^[61]两种。

递归机器学习算法的鲁棒性要求更高,原因在于递归算法的一部分输入来自于上一步的输出,可能导致算法误差的累积效应,致使算法丧失鲁棒性。然而,不同算法的误差累积效应严重程度不同,例如文献[26]中比较了LSTM-RNN和NARXNN的SOC估计性能,使用试错法确定两者的最优参数,两者均表现出估计值累积误差,但NARXNN比LSTM-RNN更严重。解决递归算法的误差累积问题的途径之一是应用传统滤波器进行算法定时校正,例如构建卡尔曼滤波器和机器学习的融合算法,以安时积分法和GRU-RNN分别作为SOC估算结果的状态方程和

观测方程,结果显示该方法能够校正GRU-RNN的累积误差^[35]。

2.3 超参数的确定

影响机器学习算法性能的关键因素之一是超参数。与径向基核函数和多项式核函数相比,一种混合核函数的LSSVM估计SOH的RMSE值小0.1%~0.2%^[82]。但算法的最优超参数值却与训练数据密切相关。例如,使用回溯搜索优化算法(backtracking search optimization algorithm, BSA)估计SOC的RBFNN和ELM的隐藏层节点数,不同温度和工况的数据驱动的网络隐含层节点数各不相同,最大相差1.5~2倍^[20]。

超参数可采用试错法、经验法或优化算法等来确定。例如,由试错法确定CNN卷积层层数^[46]和NARXNN的输入延时阶数和反馈延时阶数^[26],由经验法确定BPNN的隐层节点数^[83]。

超参数的优化算法种类多,例如PSO算法用来优化RVM核函数加权系数和内部参数^[40],量子粒子群算法(quantum-behaved particle swarm optimization algorithm, QPSO)算法用来优化多核RVM核函数加权系数^[58],ACO优化Elman NN隐层节点数^[24]、BSA优化BPNN隐层节点数^[20]、k折交叉验证法用于优化最小二乘支持向量机的超参数^[28],贝叶斯优化算法用于SVR超参数寻优^[84],梯度下降法确定高斯过程超参数最优值^[85]。不同的优化算法得到的超参数对算法的效果不同,例如由GA优化的SVR比交叉验证法网格寻优的SOC预测精度提高了0.3%~0.9%^[84]。注意,超参数优化会增加算法的复杂度和计算负担。

2.4 数据预处理

常规数据预处理方法包括数据缺失与重复处理、滤波、重采样、特征选择、特征缩放和数据集划分等。滤波主要是为了滤除数据噪声,数据的重采样是为了选择有效数据^[80,86]。特征缩放是指采用归一化、标准化和中心化等方法处理数据,用于消除不同特征数值范围的差异^[87-88]。此外,为了防止算法过拟合,数据往往叠加高斯噪声,增加样本数据的随机性^[80,57]。

2.4.1 RUL预测数据预处理

RUL是通过预测电池容量,再依据电池容量衰减曲线而获得的。就趋势而言,锂离子电池容量随着充放电循环次数的增多而不断衰减,然而容量再生现象^[78]使容量衰减曲线的变化趋势难以预测,应

采用特殊方法处理容量衰减曲线,比如高低频成分的小波分解^[78]、经验模态分解^[89]和集合经验模态分解^[58]等方法。

2.4.2 SOH估计数据预处理

在样本数据的特征选择阶段,SOC估计算法选择某一时刻的电流、电压和温度等数据,而SOH估计则选择与容量衰减相关的特征数据(健康因子)。由于电池容量变化的长久性,SOH估计所能够选择的健康因子相对较多。在单次或相邻几次充放电循环内,可认为SOH不变,因此可从短时充放电循环数据提取特征,建立健康因子与SOH的函数关系。

电池放电工况电流、温度和工作时间的不确定性导致健康因子提取困难,因此SOH估计的健康因子以充电工况数据提取为主,例如充电时某一确定电压区间变化时长、充电时某一确定电流区间变化时长^[40]、充电曲线恒流充电时间与恒压充电时间之比^[90]等。为了解决健康因子提取对完整充电循环的依赖性,可从短脉冲电流的电压响应曲线提取健康因子^[68,91],或采用极限学习机补缺不完整的充电曲线数据^[82]。

健康因子也有优化和筛选方法,比如主成分分析法^[92-94]、泊松相关系数法^[95]、灰色关联分析法^[96]、和spearman相关系数法^[59]等。此外,CNN能自提取健康因子^[46]。

2.4.3 数据集划分

数据集一般划分为训练集、验证集和测试集。训练集用于训练模型,验证集用于评估模型,防止模型过拟合,保证模型的泛化能力。测试集则用于评估模型性能。训练集、验证集和测试集可按照一定比例随机划分数据集数据。

在SOC估计问题中,测试集和训练集可采用两组截然不同的工况验证模型的泛化性^[27]。在SOH估计问题中,为了验证模型的外延估计能力,训练集可选前段充放电循环的数据,测试集则选后半段充放电的数据^[97]。对于RUL预测,可采用容量衰减曲线的前段、中段和后段分别作为训练集、验证集和测试集,验证集具有矫正模型预测趋势的能力^[56]。

2.5 模型训练

相比于传统机器学习方法如SVR、LSSVM、GP、RVM、RF、Adaboost和GBT等,神经网络训练复杂而差异性大。模型训练的目的在于以较低的成本获取一个拟合程度适中的模型,即既不过拟合,也不欠拟合,成本较低,收敛速度较快,内存占用较小。欠拟

合表示该模型在训练集上拟合精度低、误差大,过拟合则表示该模型在训练集以外的数据拟合精度低、误差大。一方面神经网络具有强大的非线性映射能力,很容易出现过拟合现象^[98];另一方面神经网络并不是凸优化问题,导致其求解过程中可能陷入局部极小值点^[99]而出现欠拟合。因此选择合适的训练算法对于模型的性能十分重要。

神经网络算法一般采用梯度下降算法对网络进行求解,恰当的求解算法有助于加快收敛速度和取得较好的训练结果。根据数据量将梯度下降法分为随机梯度下降法、小批量梯度下降法和批量梯度下降法。为了加快收敛速度和减小陷入局部极小值的概率,一些新的算法如带动量的梯度下降法、Adagrad、Adadelat、RMSprop 和 Nadam 也被用于神经网络的算法求解^[100]。文献[22]中比较了至少6种算法分析 MLP 和 LSTM-RNN 估计 SOC 的误差影响,结果显示 MLP 应用 Adadelat 和 Nadam 算法求解的效果最好,而 LSTM RNN 则应用 RMSProp 和 AdaGrad 算法求解的效果最好。

防止算法过拟合有 L1 正则化^[101]、L2 正则化^[102]、早停^[103]、Dropout^[104]和 k-折交叉验证^[105]等方法,相应效果存在差异。文献[79]中比较了避免算法过拟合的电池 RUL 预测结果,结果表明 Dropout、L1 正则化和 L2 正则化算法预测 RUL 可分别少了 16、77 和 153 个循环数,而没有采取防止过拟合方法的算法则无法预测 RUL。

3 总结与展望

针对锂离子电池 BMS 的 SOC 估计、SOH 估计和 RUL 预测问题,归纳了机器学习算法的问题求解方法和研究进展,阐述电池状态估计机器学习方法实施过程的关键问题,包括数据准备、模型选择、算法评价、超参数确定、数据预处理和模型训练。其中,提出了评价相关机器学习算法的精度、成本和鲁棒性 3 大指标。算法的实施成本差异大,如 LSTM-RNN、GRU-RNN 和 CNN 等虽能取得较高的估计精度,但训练时间长,成本高。然而,现有研究关注于算法精度,缺少对算法的实施成本和鲁棒性的评估。

尽管电池状态估计方法趋向多机器学习算法融合,但超参数确定仍然是机器学习算法的一个难点。现有确定方法的通用性差,原因在于:超参数缺少明确的物理意义,最优超参数依赖于样本数据,导致花

费大量成本训练好的模型仅能应用于特定场景,而新的场景下必须使用新的数据重新训练模型。随着电池的老化,估计模型出现不适应性,但如果丢弃原有的模型和数据,将导致训练成本的升高和面临着数据不足的风险。

因此,鉴于机器学习已进入了流程化的研究阶段,应构建自主的、具普适性的、多区域、跨季节、多模式和长时间的车用电池工况数据库,更好地促进电池状态估计的机器学习算法研究,包括评估不同算法的成本和鲁棒性,增强机器学习算法的实用性、根据数据特性确定机器学习算法的超参数的方法和增强机器学习算法的通用性的途径。

参考文献

- [1] ZOU Y, HU X, MA H, et al. Combined state of charge and state of health estimation over lithium-ion battery cell cycle lifespan for electric vehicles [J]. *Journal of Power Sources*, 2015, 273: 793-803.
- [2] XIONG R, CAO J, YU Q, et al. Critical review on the battery state of charge estimation methods for electric vehicles [J]. *IEEE Access*, 2018, 6: 1832-1843.
- [3] 罗勇, 祁朋伟, 黄欢, 等. 基于容量修正的安时积分 SOC 估算方法研究 [J]. *汽车工程*, 2020, 42(5): 681-687.
LUO Y, QI P, HUANG H, et al. Study on battery SOC estimation by ampere-hour integral method with capacity correction [J]. *Automotive Engineering*, 2020, 42(5): 681-687.
- [4] ABOUCHABAKA J, BOUREKKADI S, OMARI O, et al. Fitting the OCV-SOC relationship of a battery lithium-ion using genetic algorithm method [C]. *EDP Sciences*, 2021.
- [5] 谢旺. 基于 Thevenin 等效电路模型的锂离子电池组 SOC 估算研究 [D]. 上海: 上海交通大学, 2013.
XIE W. Study on SOC estimation of lithium-ion battery module based on thevenin equivalent circuit model [D]. Shanghai: Shanghai Jiao Tong University, 2013.
- [6] 张文华, 吴三毛, 刘平, 等. C/LiFePO₄ 动力电池电化学交流阻抗谱的研究 [J]. *电源技术*, 2015, 39(9): 1838-1842.
ZHANG W, WU S, LIU P, et al. Study on EIS of C/LiFePO₄ power battery [J]. *Chinese Journal of Power Sources*, 2015, 39(9): 1838-1842.
- [7] 徐鑫珉, 王练, 史慧玲. 基于电化学阻抗谱的电池老化寿命研究 [J]. *电源技术*, 2015, 39(12): 2579-2583.
XU X, WANG L, SHI H. Research on battery aging mechanisms based on electrochemical impedance spectroscopy [J]. *Chinese Journal of Power Sources*, 2015, 39(12): 2579-2583.
- [8] SU R, LIU L, ZHANG T, et al. An online capacity estimation method for LiFePO₄ battery module with incremental capacity curve processed by tracking differentiator under noises [C]. *SPIE*, 2020.
- [9] 华寅, 许敏. 基于双非线性预测滤波法的锂离子电池 SOH 估

- 计[J]. 电源技术, 2018, 42(9):1321-1324.
- HUA Y, XU M. State of health estimation of lithium ion battery by dual nonlinear predictive filter for electric vehicles [J]. Chinese Journal of Power Sources, 2018, 42(9):1321-1324.
- [10] CEN Z, KUBIAK P. Lithium-ion battery SOC/SOH adaptive estimation via simplified single particle model[J]. International Journal of Energy Research, 2020, 44(15):12444-12459.
- [11] ASHWIN T R, CHUNG Y M, WANG J. Capacity fade modelling of lithium-ion battery under cyclic loading conditions[J]. Journal of Power Sources, 2016, 328:586-598.
- [12] WANG A, CHEN H, JIN P, et al. RUL estimation of lithium-ion power battery based on DEKF algorithm[C]. Institute of Electrical and Electronics Engineers Inc, 2019: 1851-1856.
- [13] HECHT-NIELSEN R. Theory of the backpropagation neural network[C]. Piscataway, Washington, DC, USA: Publ by IEEE, 1989: 593-605.
- [14] PARK J, SANDBERG I W. Universal approximation using radial-basis-function networks[J]. Neural Computation, 1991, 3(2): 246 - 257.
- [15] 刘兴涛, 李坤, 武骥, 等. 基于EKF-SVM算法的动力电池SOC估计[J]. 汽车工程, 2020, 42(11):1522-1528, 1544.
- LIU X, LI K, WU J, et al. State of charge estimation for traction battery based on EKF-SVM algorithm[J]. Automotive Engineering, 2020, 42(11):1522-1528, 1544.
- [16] 戴海峰, 姜波, 魏学哲, 等. 基于充电曲线特征的锂离子电池容量估计[J]. 机械工程学报, 2019, 55(20):52 - 59.
- DAI H, JIANG B, WEI X, et al. Capacity estimation of lithium-ion batteries based on charging curve features[J]. Journal of Mechanical Engineering, 2019, 55(20):52-59.
- [17] 周頔, 宋显华, 卢文斌, 等. 基于日常片段充电数据的锂电池健康状态实时评估方法研究[J]. 中国电机工程学报, 2019, 39(01):105-111, 325.
- ZHOU D, SONG X, LU W, et al. Real-time SOH estimation algorithm for lithium-ion batteries based on daily segment charging data[J]. Proceedings of the Chinese Society of Electrical Engineering, 2019, 39(1):105-111, 325.
- [18] HU X, YANG X, FENG F, et al. A particle filter and long short-term memory fusion technique for lithium-ion battery remaining useful life prediction[J]. Journal of Dynamic Systems, Measurement and Control, Transactions of the ASME, 2021, 143(6).
- [19] 鲍伟, 葛建军. 基于稀疏采样数据的电动公交车电池SOC预测方法研究[J]. 汽车工程, 2020, 42(3):367-374.
- BAO W, GE J. Study on battery SOC prediction method for electric bus based on sparsely sampled data[J]. Automotive Engineering, 2020, 42(3):367 - 374.
- [20] HANNAN M A, LIPU M, HUSSAIN A, et al. Neural network approach for estimating state of charge of lithium-ion battery using backtracking search algorithm [J]. IEEE Access, 2018, 6: 10069-10079.
- [21] LIPU M H, HANNAN M A, HUSSAIN A, et al. Extreme learning machine model for state-of-charge estimation of lithium-ion battery using gravitational search algorithm [J]. IEEE Transactions on Industry Applications, 2019, 55(4): 4225-4234.
- [22] KHALID A, SUNDARARAJAN A, ACHARYA I, et al. Prediction of Li-ion battery state of charge using multilayer perceptron and long short-term memory models[C]. Institute of Electrical and Electronics Engineers Inc, 2019.
- [23] HANNAN M A, HOW D, HOSSAIN LIPU M S, et al. SOC estimation of Li-ion batteries with learning rate-optimized deep fully convolutional network[J]. IEEE Transactions on Power Electronics, 2021, 36(7):7349-7353.
- [24] ZHAO X, XUAN D, ZHAO K, et al. Elman neural network using ant colony optimization algorithm for estimating of state of charge of lithium-ion battery [J]. Journal of Energy Storage, 2020, 32:101789.
- [25] HOSSAIN LIPU M S, HUSSAIN A, SAAD M, et al. Improved recurrent NARX neural network model for state of charge estimation of lithium-ion battery using pso algorithm[C]. Institute of Electrical and Electronics Engineers Inc, 2018: 354-359.
- [26] ABBAS G, NAWAZ M, KAMRAN F. Performance comparison of NARX RNN-LSTM neural networks for LiFePO4 battery state of charge estimation[C]. Institute of Electrical and Electronics Engineers Inc, 2019: 463-468.
- [27] CHEMALI E, KOLLMAYER P J, PREINDL M, et al. Long short-term memory networks for accurate state-of-charge estimation of Li-ion batteries[J]. IEEE Transactions on Industrial Electronics, 2018, 65(8):6730-6739.
- [28] 李嘉波, 李忠玉, 焦生杰, 等. 基于反馈最小二乘支持向量机锂离子状态估计[J]. 储能科学与技术, 2020, 9(3):951-957.
- LI J, LI Z, JIAO S, et al. Lithium-ion state estimation based on feedback least square support vector machine [J]. Energy Storage Science and Technology, 2020, 9(3):951-957.
- [29] XIAO F, LI C, FAN Y, et al. State of charge estimation for lithium-ion battery based on Gaussian process regression with deep recurrent kernel[J]. International Journal of Electrical Power and Energy Systems, 2021, 124.
- [30] 陈德海, 马原, 潘韦驰. 改进 PSO-RBF 模型的分阶查表法荷电状态估计[J]. 储能科学与技术, 2019, 8(6):1190 - 1196.
- CHEN D, MA Y, PAN W. Improved state-of-the-art look-up table method for charge state estimation of PSO-RBF model[J]. Energy Storage Science and Technology, 2019, 8(6):1190-1196.
- [31] CIVICIOGLU P. Backtracking search optimization algorithm for numerical optimization problems [J]. Applied Mathematics and Computation, 2013, 219(15):8121-8144.
- [32] FASAHAT M, MANTHOURI M. State of charge estimation of lithium-ion batteries using hybrid autoencoder and long short term memory neural networks [J]. Journal of Power Sources, 2020, 469:228375.
- [33] 孔祥创, 赵万忠, 王春燕. 基于BP-EKF算法的锂电池SOC联合估计[J]. 汽车工程, 2017, 39(6):648-652.
- KONG X, ZHAO W, WANG C. Co-estimation of Lithium battery SOC based on BP-EKF algorithm [J]. Automotive Engineering,

- 2017, 39(6):648-652.
- [34] SINGH K V, BANSAL H O, SINGH D. Hardware-in-the-loop implementation of ANFIS based adaptive SoC estimation of lithium-ion battery for hybrid vehicle applications[J]. Journal of Energy Storage, 2020, 27.
- [35] 李超然, 肖飞, 樊亚翔, 等. 基于门控循环单元神经网络和 Huber-M 估计鲁棒卡尔曼滤波融合方法的锂离子电池荷电状态估算方法[J]. 电工技术学报, 2020, 35(9):2051-2062.
- LI C, XIAO F, FAN Y, et al. A hybrid approach to lithium-ion battery SOC estimation based on recurrent neural network with gated recurrent unit and huber-M robust Kalman filter[J]. Transactions of China Electrotechnical Society, 2020, 35(9):2051-2062.
- [36] WANG Q. Battery state of charge estimation based on multi-model fusion[C]. Institute of Electrical and Electronics Engineers Inc, 2019: 2036-2041.
- [37] 范兴明, 王超, 张鑫, 等. 基于增量学习相关向量机的锂离子电池 SOC 预测方法[J]. 电工技术学报, 2019, 34(13):2700-2708.
- FAN X, WANG C, ZHANG X, et al. A prediction method of lithium-ion batteries SOC based on incremental learning relevance vector machine[J]. Transactions of China Electrotechnical Society, 2019, 34(13):2700-2708.
- [38] 刘昊天, 王萍, 程泽. 一种编解码器模型的锂离子电池健康状态估算[J]. 中国电机工程学报, 2020:1-9.
- LIU H, WANG P, CHENG Z. A novel method based on encoder-decoder framework for Li-ion battery state of health estimation[J]. Proceedings of the Chinese Society of Electrical Engineering, 2021, 41(5):1851-1859.
- [39] 徐宏东, 高海波, 林治国, 等. 基于 CS-SVR 模型的锂离子电池 SOH 预测[J]. 电池, 2020, 50(5):424-427.
- XU H, GAO H, LIN Z, et al. Prediction for SOH of Li-ion battery based on CS-SVR model[J]. Battery Bimonthly, 2020, 50(5):424-427.
- [40] ZHANG Y, YAO H, QI J J, et al. Real-time capacity estimation of lithium-ion batteries using a novel ensemble of multi-kernel relevance vector machines[C]. Institute of Electrical and Electronics Engineers Inc, 2019: 230-236.
- [41] 徐元中, 曹翰林, 吴铁洲. 基于 SA-BP 神经网络算法的电池 SOH 预测[J]. 电源技术, 2020, 44(3):341-345.
- XÜ Y, CAO H, WU T. Estimation of SOH for battery based on SA-BP neural network[J]. Chinese Journal of Power Sources, 2020, 44(3):341-345.
- [42] 周才杰, 汪玉洁. 基于自动编码器特征提取的锂电池健康状态估计[C]. 第 21 届中国系统仿真技术及其学术年会论文集 (CCSSTA21st 2020), 2020.
- ZHOU C, WANG Y. State of health estimation for lithium-ion battery based on the feature extracted by auto-encoder[C]. CCSSTA21st, 2020.
- [43] 潘海鸿, 吕治强, 付兵, 等. 采用极限学习机实现锂离子电池健康状态在线估算[J]. 汽车工程, 2017, 39(12):1375-1381, 1396.
- PAN H, LÜ Z, FU B, et al. Online estimation of lithium-ion battery's state of health using extreme learning machine[J]. Automotive Engineering, 2017, 39(12):1375-1381, 1396.
- [44] LEE J H, KIM H S, LEE I S. Multilayer neural network-based battery module SOH diagnosis[J]. International Journal of Engineering Research and Technology, 2020, 13(2):316-319.
- [45] KHUMPROM P, YODO N. A data-driven predictive prognostic model for lithium-ion batteries based on a deep learning algorithm[J]. Energies, 2019, 12(4).
- [46] SHEN S, SADOUGHI M, CHEN X, et al. A deep learning method for online capacity estimation of lithium-ion batteries[J]. Journal of Energy Storage, 2019, 25:100817.
- [47] RAHBARI O, MAYET C, OMAR N, et al. Battery aging prediction using input-time-delayed based on an adaptive neuro-fuzzy inference system and a group method of data handling techniques[J]. Applied Sciences (Switzerland), 2018, 8(8).
- [48] KIM S J, KIM S H, LEE H M, et al. State of health estimation of Li-ion batteries using multi-input LSTM with optimal sequence length[C]. Institute of Electrical and Electronics Engineers Inc, 2020: 1336-1341.
- [49] KENNEDY J, EBERHART R. Particle swarm optimization[C]. Piscataway, NJ, United States: IEEE, 1995: 1942-1948.
- [50] GUO W, LI S, MIAO Q, et al. A deep learning method with ensemble learning for capacity estimation of lithium-ion battery[C]. Institute of Electrical and Electronics Engineers Inc, 2020.
- [51] LI Y, ZOU C, BEREICIBAR M, et al. Random forest regression for online capacity estimation of lithium-ion batteries[J]. Applied Energy, 2018, 232:197-210.
- [52] SHEN S, SADOUGHI M, LI M, et al. Deep convolutional neural networks with ensemble learning and transfer learning for capacity estimation of lithium-ion batteries[J]. Applied Energy, 2020, 260:114296.
- [53] ZHANG Y, XIONG R, HE H, et al. A LSTM-RNN method for the lithium-ion battery remaining useful life prediction[C]. 2017 Prognostics and System Health Management Conference (PHM-Harbin), 2017: 1-4.
- [54] SONG Y, LI L, PENG Y, et al. Lithium-ion battery remaining useful life prediction based on GRU-RNN[C]. Institute of Electrical and Electronics Engineers Inc, 2018: 317-322.
- [55] GOU B, XU Y, FANG S, et al. Remaining useful life prediction for lithium-ion battery using ensemble learning method[C]. IEEE Computer Society, 2019.
- [56] CHENG Y, SONG D, WANG Z, et al. An ensemble prognostic method for lithium-ion battery capacity estimation based on time-varying weight allocation[J]. Applied Energy, 2020, 266:114817.
- [57] SUSILO D D, WIDODO A, PRAHASTO T, et al. State of health estimation of lithium-ion batteries based on combination of gaussian distribution data and least squares support vector machines regression[M]. Trans Tech Publications Ltd, 2018.

- [58] 张朝龙, 何怡刚, 袁莉芬. 基于 EEMD 和 MKRVM 的锂电池剩余寿命预测方法[J]. 电力系统及其自动化学报, 2018, 30(7):38-44.
- ZHANG C, HE Y, YUAN L. Prediction approach for remaining useful life of lithium-ion battery based on EEMD and MKRVM[J]. Proceedings of the CSU-EPSA, 2018, 30(7):38-44.
- [59] LIU J, CHEN Z. Remaining useful life prediction of lithium-ion batteries based on health indicator and Gaussian process regression model[J]. IEEE Access, 2019, 7:39474-39484.
- [60] SBARUFATTI C, CORBETTA M, GIGLIO M, et al. Adaptive prognosis of lithium-ion batteries based on the combination of particle filters and radial basis function neural networks[J]. Journal of Power Sources, 2017, 344:128-140.
- [61] LIU W, YAN L, ZHANG X, et al. A denoising SVR-MLP method for remaining useful life prediction of lithium-ion battery[C]. Institute of Electrical and Electronics Engineers Inc, 2019: 545-550.
- [62] REN L, DONG J, WANG X, et al. A data-driven auto-CNN-LSTM prediction model for lithium-ion battery remaining useful life[J]. IEEE Transactions on Industrial Informatics, 2021, 17(5):3478-3487.
- [63] GUARINO A, ZAMBONI W, MONMASSON E. A comparison of ensemble machine learning techniques for the estimate of residual capacity of Li-ion batteries[C]. Institute of Electrical and Electronics Engineers Inc, 2020: 1307-1312.
- [64] YANG F, WANG D, XU F, et al. Lifespan prediction of lithium-ion batteries based on various extracted features and gradient boosting regression tree model[J]. Journal of Power Sources, 2020, 476:228654.
- [65] Global technical regulation No. 15 (Worldwide harmonized light vehicles test procedure)[EB/OL]. [2021-04-16]. <https://unece.org/transport/standards/transport/vehicle-regulations-wp29/global-technical-regulations-gtrs>.
- [66] Addenda to the 1958 agreement (Regulations NO. 101 and NO.83)[EB/OL]. [2021-04-16]. <https://unece.org/transport/vehicle-regulations-wp29/standards/addenda-1958-agreement-regulation-101-120>.
- [67] 孙逢春, 孟祥峰, 林程, 等. 电动汽车动力电池动态测试工况研究[J]. 北京理工大学学报, 2010, 30(3):297-301.
- SUN F, MENG X, LIN C, et al. Dynamic stress test profile of power battery for electric vehicle[J]. Transactions of Beijing Institute of Technology, 2010, 30(3):297-301.
- [68] MENG J, CAI L, D-ISTROE, et al. An optimized ensemble learning framework for lithium-ion battery state of health estimation in energy storage system[J]. Energy, 2020, 206:118140.
- [69] SAHA B, GOEBEL K. Battery data set[DB/OL]. NASA Ames Prognostics Data Repository, 2007. <https://ti.arc.nasa.gov/tech/dash/groups/pcoe/prognostic-data-repository/publications/#battery>.
- [70] BOLE B, KULKARNI C, DAIGLE M. Randomized battery usage data set[DB/OL]. NASA Ames Prognostics Data Repository, NASA Ames Research Center, 2014. <https://ti.arc.nasa.gov/tech/dash/groups/pcoe/prognostic-data-repository/publications/#battery>.
- [71] Battery data center for advanced life cycle engineering[EB/OL]. [2021-03-24]. <https://calce.umd.edu/battery-data>.
- [72] SEVERSON K A, ATTIA P M, JIN N, et al. Data-driven prediction of battery cycle life before capacity degradation[J]. Nature Energy, 2019, 4(5):383-391.
- [73] ATTIA P M, GROVER A, JIN N, et al. Closed-loop optimization of fast-charging protocols for batteries with machine learning[J]. Nature, 2020, 578(7795):397-402.
- [74] BIRKL C. Oxford battery degradation dataset 1. university of oxford, 2017 [DB/OL]. <https://ora.ox.ac.uk/objects/uuid%3A03ba4b01-cfed-46d3-9b1a-7d4a7bdf6fac>.
- [75] KOLLMEYER P. Panasonic 18650PF Li-ion battery data[R]. 2018.
- [76] ZHANG H, TANG W, NA W, et al. Implementation of generative adversarial network-CLS combined with bidirectional long short-term memory for lithium-ion battery state prediction[J]. Journal of Energy Storage, 2020, 31:101489.
- [77] DASZYKOWSKI M, KACZMAREK K, VANDER HEYDEN Y, et al. Robust statistics in data analysis-a review: basic concepts[J]. Chemometrics and Intelligent Laboratory Systems, 2007, 85(2):203-219.
- [78] PANG X, HUANG R, WEN J, et al. A lithium-ion battery rule prediction method considering the capacity regeneration phenomenon[J]. Energies, 2019, 12(11)..
- [79] ZHANG Y, XIONG R, HE H, et al. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries[J]. IEEE Transactions on Vehicular Technology, 2018, 67(7):5695-5705.
- [80] FAN Y, XIAO F, LI C, et al. A novel deep learning framework for state of health estimation of lithium-ion battery[J]. Journal of Energy Storage, 2020, 32.
- [81] XIA B, CUI D, SUN Z, et al. State of charge estimation of lithium-ion batteries using optimized Levenberg-Marquardt wavelet neural network[J]. Energy, 2018, 153:694-705.
- [82] SHU X, LI G, ZHANG Y, et al. Online diagnosis of state of health for lithium-ion batteries based on short-term charging profiles[J]. Journal of Power Sources, 2020, 471.
- [83] LONG WANG, NANNING ZHENG, CHUAN WANG. The hidden nodes of BP neural nets and the activation functions[C]. 1991 International Conference on Circuits and Systems, 1991: 77-79.
- [84] 史永胜, 马铭远, 丁恩松, 等. 改进支持向量回归的锂离子电池可用容量估计[J]. 电源技术, 2019, 43(12):1996-2000.
- SHI Y, MA M, DING E, et al. Capacity estimation of lithium ion battery based on support vector regression[J]. Chinese Journal of Power Sources, 2019, 43(12):1996-2000.
- [85] 李嘉波, 魏孟, 叶敏, 等. 基于高斯过程回归的锂离子电池 SOC 估计[J]. 储能科学与技术, 2020, 9(1):131-137.
- LI J, WEI M, YE M, et al. SOC estimation of lithium-ion batteries based on Gauss process regression[J]. Energy Storage Sci-

- ence and Technology, 2020, 9(1):131-137.
- [86] WU J, ZHANG C, CHEN Z. An online method for lithium-ion battery remaining useful life estimation using importance sampling and neural networks [J]. Applied Energy, 2016, 173: 134-140.
- [87] ALTMAN N S. An introduction to kernel and nearest-neighbor nonparametric regression [J]. The American Statistician, 1992, 46(3):175-185.
- [88] IOFFE S, SZEGEDY C. Batch normalization: accelerating deep network training by reducing internal covariate shift[R]. 2015.
- [89] 郑雪莹, 邓晓刚, 曹玉苹. 基于能量加权高斯过程回归的锂离子电池健康状态预测[J]. 电子测量与仪器学报, 2020, 34(6):63-69.
- ZHENG X, DENG X, CAO Y. State of health prediction of lithium-ion batteries based on energy-weighted Gaussian process regression [J]. Journal of Electronic Measurement and Instrumentation, 2020, 34(6):63-69.
- [90] LI Y, SHENG H, CHENG Y, et al. State-of-health estimation of lithium-ion batteries based on semi-supervised transfer component analysis[J]. Applied Energy, 2020, 277:115504.
- [91] MENG J, CAI L, LUO G, et al. Lithium-ion battery state of health estimation with short-term current pulse test and support vector machine [J]. Microelectronics Reliability, 2018, 88-90: 1216-1220.
- [92] 孙道明, 俞小莉. 随机放电工况下锂离子电池容量预测方法[J]. 汽车工程, 2020, 42(9):1189-1196.
- SUN D, YU X. Capacity prediction method of lithium-ion battery under random discharge condition [J]. Automotive Engineering, 2020, 42(9):1189-1196.
- [93] 王竹晴, 庞晓琼, 黄蕊, 等. 基于KPCA-ANFIS的锂离子电池RUL预测[J]. 电子测量与仪器学报, 2018, 32(10):26-32.
- WANG Z, PANG X, HUANG R, et al. KPCA-ANFIS based remaining useful life prediction of lithium-ion battery [J]. Journal of Electronic Measurement and Instrumentation, 2018, 32(10): 26-32.
- [94] SCHÖLKOPF B, SMOLA A, K-RMÜLLER. Nonlinear component analysis as a kernel eigenvalue problem [J]. Neural Computation, 1998, 10(5):1299-1319.
- [95] GOU B, XU Y, FENG X. State-of-health estimation and remaining-useful-life prediction for lithium-ion battery using a hybrid data-driven method [J]. IEEE Transactions on Vehicular Technology, 2020, 69(10):10854-10867.
- [96] GUO P, CHENG Z, YANG L. A data-driven remaining capacity estimation approach for lithium-ion batteries based on charging health feature extraction [J]. Journal of Power Sources, 2019, 412:442-450.
- [97] YANG D, ZHANG X, PAN R, et al. A novel Gaussian process regression model for state-of-health estimation of lithium-ion battery using charging curve [J]. Journal of Power Sources, 2018, 384:387-395.
- [98] HAWKINS D M. The problem of overfitting [J]. Journal of Chemical Information and Computer Sciences, 2004, 44(1):1-12.
- [99] BISHOP C M. Pattern recognition and machine learning [M]. Springer, 2006.
- [100] RUDERSEBASTIAN. An overview of gradient descent optimization algorithms [J]. CoRR, 2016, abs/1609.04747.
- [101] TIBSHIRANI R. Regression shrinkage and selection via the lasso: a retrospective [J]. Journal of the Royal Statistical Society. Series B: Statistical Methodology, 2011, 73(3):273-282.
- [102] HOERL A E, KENNARD R W. Ridge regression: biased estimation for nonorthogonal problems [J]. Technometrics, 1970, 12(1):55-67.
- [103] CARUANA R, LAWRENCE S, GILES L. Overfitting in neural nets: backpropagation, conjugate gradient, and early stopping [C]. Neural Information Processing Systems Foundation, 2001.
- [104] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a simple way to prevent neural networks from overfitting [J]. Journal of Machine Learning Research, 2014, 15:1929-1958.
- [105] JAMES G, WITTEN D, HASTIE T, et al. An introduction to statistical learning: with applications in R [M]. New York: Springer, 2013.

(上接第1701页)

- [10] ZHENG C, CHA S W. Real-time application of Pontryagin's minimum principle to fuel cell hybrid buses based on driving characteristics of buses [J]. International Journal of Precision Engineering and Manufacturing-Green Technology, 2017, 4(2): 199-209.
- [11] 姚颖方, 刘建国, 邹志刚. 燃料电池膜电极衰减机制及其老化策略 [J]. 电化学, 2018, 24(6): 664-676.
- YAO Y F, LIU J G, ZOU Z G. Degradation mechanism and anti-aging strategies of membrane electrode assembly of fuel cells [J]. Journal of Electrochemistry, 2018, 24(6): 664-676.
- [12] 杨勇, 张洪飞, 罗马吉. 基于PLC的燃料电池控制系统研究 [J]. 公路与汽运, 2011(3): 1-4.
- YANG Y, ZHANG H F, LUO M J. Research on fuel cell control system based on PLC [J]. Highways & Automotive Applications, 2011(3): 1-4.
- [13] 伍沛亮, 李沫林. 动力磷酸铁锂电池组充电技术研究 [J]. 科技经济导刊, 2017(3): 106.
- WU P L, LI M L. Research on charging technology of power LiFePO4 battery stack [J]. Technology and Economic Guide, 2017(3): 106.